Rapport à rendre en économétrie - Master 1

INTRODUCTION

Ce rapport rassemble les réponses aux trois exercices proposés dans le cadre de l'examen d'économétrie. L'objectif commun est d'appliquer différents modèles économétriques adaptés à la nature des variables étudiées, afin d'analyser des comportements individuels, des choix discrets et des relations macroéconomiques.

Le premier exercice s'inscrit dans un cadre de choix binaire et mobilise un modèle logit fondé sur une variable latente pour analyser une décision de confiance individuelle. Il permet d'illustrer l'estimation par maximum de vraisemblance, l'interprétation des coefficients et le calcul des effets marginaux.

Le deuxième exercice porte sur une variable ordinale de santé auto-déclarée. Il conduit à l'utilisation d'un modèle probit ordonné, reposant également sur une variable latente, et met l'accent sur l'interprétation probabiliste des résultats ainsi que sur les effets marginaux associés à chaque modalité.

Enfin, le troisième exercice adopte une perspective macroéconomique et exploite des données de panel pour étudier le lien entre température et croissance économique. Il mobilise successivement des estimations en coupe transversale, des modèles à effets fixes, des spécifications Two-Way Fixed Effects et une comparaison entre effets fixes et effets aléatoires.

L'ensemble du rapport vise ainsi à illustrer la cohérence entre la structure des données, les hypothèses économétriques retenues et les méthodes d'estimation mises en œuvre, tout en discutant les limites et les conditions d'interprétation des résultats obtenus.

DECEMBRE 2025

Antoine Jean

Exercice 1 – Trust decision (Logit)

1. Modèle à variable latente et probabilité conditionnelle

On considère le modèle latent

$$y_i^* = a_0 + a_1 r_i + a_2 p_i + u_i, \qquad y_i = \begin{cases} 1 & \text{si } y_i^* > 0, \\ 0 & \text{si } y_i^* \leq 0, \end{cases}$$

où u_i est continu, de fonction de répartition $F(\cdot)$ et de densité $f(\cdot)$, avec symétrie autour de 0 : $F(-x) = 1 - F(x)$ et $f(-x) = f(x)$.

Alors,

$$\begin{aligned} \mathbb{P}(y_i = 1 \mid r_i, p_i) &= \mathbb{P}(y_i^* > 0 \mid r_i, p_i) = \mathbb{P}\left(u_i > -(a_0 + a_1 r_i + a_2 p_i) \mid r_i, p_i\right) \\ &= 1 - F\left(-(a_0 + a_1 r_i + a_2 p_i)\right) = F(a_0 + a_1 r_i + a_2 p_i), \end{aligned}$$

en utilisant $1 - F(-x) = F(x)$.

2. Log-vraisemblance et maximum de vraisemblance

En notant $\pi_i \equiv \mathbb{P}(y_i = 1 \mid r_i, p_i) = F(a_0 + a_1 r_i + a_2 p_i)$, la vraisemblance d'une observation est

$$\mathbb{P}(y_i \mid r_i, p_i) = \pi_i^{y_i} (1 - \pi_i)^{1 - y_i}.$$

Sur l'échantillon ($N = 100$), la log-vraisemblance s'écrit :

$$\ell_N(a_0, a_1, a_2; y \mid r, p) = \sum_{i=1}^{100} y_i \log\Big(F(a_0 + a_1 r_i + a_2 p_i)\Big) + \sum_{i=1}^{100} (1 - y_i) \log\Big(1 - F(a_0 + a_1 r_i + a_2 p_i)\Big).$$

L'estimateur du maximum de vraisemblance (MV) est défini par

$$(\hat{a}_0, \hat{a}_1, \hat{a}_2) \in \arg \max_{(a_0, a_1, a_2) \in \mathbb{R}^3} \ell_N(a_0, a_1, a_2; y \mid r, p),$$

obtenu en pratique par maximisation numérique de ℓ_N.

3. Effets marginaux : expression, MEM et AME

La probabilité conditionnelle vaut $\pi_i = F(\eta_i)$ avec $\eta_i = a_0 + a_1 r_i + a_2 p_i$. L'effet marginal de r_i sur π_i est

$$\frac{\partial \pi_i}{\partial r_i} = \frac{\partial F(\eta_i)}{\partial r_i} = f(\eta_i) \frac{\partial \eta_i}{\partial r_i} = a_1 \, f(a_0 + a_1 r_i + a_2 p_i).$$

De même,

$$\frac{\partial \pi_i}{\partial p_i} = a_2 \, f(a_0 + a_1 r_i + a_2 p_i).$$

Ces effets s'interprètent comme des variations en points de probabilité.

MEM (Marginal Effect at the Mean).

$$\mathrm{MEM}_r = a_1 \, f(a_0 + a_1 \bar{r} + a_2 \bar{p}), \qquad \mathrm{MEM}_p = a_2 \, f(a_0 + a_1 \bar{r} + a_2 \bar{p}).$$

AME (Average Marginal Effect).

$$\mathrm{AME}_r = \frac{1}{N} \sum_{i=1}^{N} a_1 \, f(a_0 + a_1 r_i + a_2 p_i), \qquad \mathrm{AME}_p = \frac{1}{N} \sum_{i=1}^{N} a_2 \, f(a_0 + a_1 r_i + a_2 p_i).$$

4. Résultats Logit (distribution logistique), interprétation et effets marginaux

On suppose u_i logistique :

$$F(t) = \Lambda(t) = \frac{1}{1+e^{-t}}, \qquad f(t) = \Lambda(t)(1-\Lambda(t)).$$

Descriptif. $N = 100$ et $\bar{y} = 0.21$. Comme y est binaire, $\bar{y}$ s'interprète comme une proportion : 21% des individus choisissent *trust*.

Estimation Logit de y sur r et p.

$$\hat{a}_0 = -6.491 \quad (\text{SE} = 1.430;\ z = -4.54;\ p < 0.001),$$

$$\hat{a}_1 = -6.651 \quad (\text{SE} = 2.951;\ z = -2.25;\ p = 0.024;\ \text{IC } 95\% \, [-12.436;\ -0.866]),$$

$$\hat{a}_2 = 0.264 \quad (\text{SE} = 0.062;\ z = 4.24;\ p < 0.001;\ \text{IC } 95\% \, [0.142;\ 0.387]).$$

Qualité globale : Log-likelihood $= -30.704$, Pseudo $R^2 = 0.402$, test LR $\chi^2(2) = 41.38$ ($p < 0.001$).

Interprétation économique. Dans un modèle Logit, les coefficients a_1 et a_2 mesurent l'effet des covariables sur l'*index latent* $a_0 + a_1 r_i + a_2 p_i$ (équivalemment sur les *log-odds*), et non un effet direct constant sur la probabilité.

- $\hat{a}_1 < 0$: une hausse de l'aversion au risque r diminue l'index latent (et les log-odds) de la décision de *trust*, ce qui tend à réduire la probabilité de *trust*, toutes choses égales par ailleurs.
- $\hat{a}_2 > 0$: une hausse de la probabilité subjective p augmente l'index latent (et les log-odds), ce qui tend à accroître la probabilité de *trust*.

L'ampleur de l'effet sur la probabilité dépend du point d'évaluation et est donc mesurée par les effets marginaux (MEM et AME) reportés ci-dessous.

Effets marginaux au point moyen (MEM).

$$\text{MEM}_r = -0.390 \quad (\text{SE} = 0.198;\ p = 0.049), \qquad \text{MEM}_p = 0.015 \quad (\text{SE} = 0.005;\ p = 0.003).$$

Effets marginaux moyens (AME).

$$\text{AME}_r = -0.648 \quad (\text{SE} = 0.252;\ p = 0.010), \qquad \text{AME}_p = 0.025 \quad (\text{SE} = 0.003;\ p < 0.001).$$

5. Probabilité prédite pour $(r_i, p_i) = (0, 0.5)$

$$\mathbb{P}(y_i = 1 \mid r_i, p_i) = \Lambda(a_0 + a_1 r_i + a_2 p_i).$$

Ainsi,

$$\widehat{\mathbb{P}}(y_i = 1 \mid r_i = 0, p_i = 0.5) = 0.001 \quad (\text{SE} = 0.002).$$

Cette valeur très faible reflète un intercept négatif et un niveau modéré de p.

6. Évaluation de la qualité d'ajustement

- **LR global :** rejet de $a_1 = a_2 = 0$ ($p < 0.001$).
- **Pseudo R^2 :** 0.402.
- **Classification (seuil 0.5) :** 86% (sensibilité 57.14%, spécificité 93.67%).
  Cette mesure dépend du seuil choisi et doit être interprétée avec prudence, la proportion de $y = 1$ étant relativement faible ($\bar{y} = 0.21$).

— **Hosmer–Lemeshow :** $\chi^2(8) = 6.88$, $p = 0.549$.

Évaluation globale. Globalement, le modèle présente un ajustement satisfaisant. Le test du rapport de vraisemblance rejette nettement le modèle nul et le pseudo-R^2 indique un gain substantiel par rapport à un modèle sans covariables. Le taux de bonne classification doit toutefois être interprété avec prudence, car il dépend du seuil retenu et la proportion d'observations avec $y = 1$ est relativement faible.

Exercice 2 – Self-assessments of health status (Ordered Probit)

Données et statistique descriptive de `health`

La variable dépendante ordinale `health` prend 5 modalités : 1=poor, 2=fair, 3=good, 4=very good, 5=excellent.

— Répartition (N total tabulé = 2125, manquants inclus) : Poor 89 (4.19%), Fair 283 (13.32%), Good 665 (31.29%), Very good 673 (31.67%), Excellent 390 (18.35%), Missing 25 (1.18%).

— Résumé (sur 2100 obs.) : moyenne = 3.472, écart-type = 1.070, min = 1, max = 5.

La taille d'échantillon varie selon les sorties : la répartition est tabulée sur $N = 2125$ (manquants inclus), le résumé sur $N = 2100$ (health non manquant), et l'estimation/prédictions sur $N = 2009$ (observations complètes sur `health` et toutes les covariables).

1. Modèle adapté

Comme `health` est une variable *ordinale* (catégories ordonnées, pas d'échelle cardinale), un modèle de réponse qualitative ordonnée est adapté : *Ordered Probit* (probit ordonné), fondé sur une variable latente continue et des seuils (cutpoints).

2. Modèle latent et probabilités des modalités (erreur normale)

On introduit une variable latente (santé sous-jacente)

$$\text{health}_i^* = x_i'\beta + u_i, \qquad u_i \sim \mathcal{N}(0,1),$$

où $x_i = (1, \text{age}_i, \text{female}_i, \text{bmi}_i, \text{exercise}_i)$ (avec `female` et `exercise` binaires).

On définit des seuils (cutpoints) $\kappa_1 < \kappa_2 < \kappa_3 < \kappa_4$ tels que

$$\text{health}_i = \begin{cases} 1 & \text{si health}_i^* \le \kappa_1, \\ 2 & \text{si } \kappa_1 < \text{health}_i^* \le \kappa_2, \\ 3 & \text{si } \kappa_2 < \text{health}_i^* \le \kappa_3, \\ 4 & \text{si } \kappa_3 < \text{health}_i^* \le \kappa_4, \\ 5 & \text{si } \kappa_4 < \text{health}_i^*. \end{cases}$$

En notant $\Phi(\cdot)$ la CDF de la loi normale standard, les probabilités conditionnelles (avec $\kappa_0 = -\infty$ et $\kappa_5 = +\infty$) sont :

$$\mathbb{P}(\text{health}_i = 1 \mid x_i) = \Phi(\kappa_1 - x_i'\beta),$$

$$\mathbb{P}(\text{health}_i = j \mid x_i) = \Phi(\kappa_j - x_i'\beta) - \Phi(\kappa_{j-1} - x_i'\beta), \quad j = 2,3,4,$$

$$\mathbb{P}(\text{health}_i = 5 \mid x_i) = 1 - \Phi(\kappa_4 - x_i'\beta).$$

3. Log-vraisemblance du modèle

En posant $y_i \in \{1,2,3,4,5\}$ la réalisation observée et $\mathbf{1}\{y_i = j\}$ l'indicatrice, la log-vraisemblance (pour un échantillon de taille N) s'écrit :

$$\ell(\beta, \kappa) = \sum_{i=1}^{N} \sum_{j=1}^{5} \mathbf{1}\{y_i = j\} \log\Big(\mathbb{P}(y_i = j \mid x_i)\Big),$$

avec $\mathbb{P}(y_i = j \mid x_i)$ donnée par les expressions de la question 2.

4. Paramètres estimables

Sous l'identification standard du probit ordonné (variance de u_i fixée à 1), on estime :

$$\beta = (\beta_{\text{age}}, \beta_{\text{female}}, \beta_{\text{bmi}}, \beta_{\text{exercise}}) \quad \text{et} \quad (\kappa_1, \kappa_2, \kappa_3, \kappa_4).$$

Remarque d'identification : l'ordonnée à l'origine n'est pas identifiée séparément des seuils (les seuils absorbent la constante).

5. Effets marginaux : expressions, MEM et AME

(a) Expressions. Pour une covariable continue x_{ik} (par ex. `age` ou `bmi`), l'effet marginal sur la probabilité de la modalité j s'écrit :

$$\frac{\partial \mathbb{P}(y_i = j \mid x_i)}{\partial x_{ik}} = \beta_k \Big[\varphi(\kappa_{j-1} - x_i'\beta) - \varphi(\kappa_j - x_i'\beta)\Big],$$

où $\varphi(\cdot)$ est la densité de la normale standard (avec la convention $\varphi(\pm\infty) = 0$).

Pour une covariable binaire $d_{ik} \in \{0, 1\}$ (ici `female` et `exercise`), l'effet pertinent est un *changement discret* :

$$\Delta_j(d_k) = \mathbb{P}(y_i = j \mid d_{ik} = 1, x_{i,-k}) - \mathbb{P}(y_i = j \mid d_{ik} = 0, x_{i,-k}),$$

plutôt qu'une dérivée.

Ces effets marginaux mesurent une *sensibilité locale* des probabilités conditionnelles à une variation marginale de la covariable considérée, évaluée en un point donné de l'espace des covariables.

(b) MEM (Marginal Effect at the Mean). Le MEM évalue l'effet marginal des covariables sur les probabilités conditionnelles en fixant le vecteur des covariables à leurs valeurs moyennes :

$$\text{MEM}_j(k) = \left.\frac{\partial \mathbb{P}(y = j \mid x)}{\partial x_k}\right|_{x=\bar{x}}.$$

Pour une covariable binaire d_k, le **MEM** correspond à $\Delta_j(d_k)$ évalué en fixant les autres covariables à leurs moyennes (et d_k passant de 0 à 1).

(c) AME (Average Marginal Effect). L'AME correspond à la moyenne, sur l'ensemble de l'échantillon, des effets marginaux individuels :

$$\text{AME}_j(k) = \frac{1}{N} \sum_{i=1}^{N} \frac{\partial \mathbb{P}(y_i = j \mid x_i)}{\partial x_{ik}}.$$

Pour une covariable binaire d_k, l'**AME** correspond à la moyenne sur i des changements discrets $\Delta_j(d_k)$ (passage de 0 à 1), en laissant $x_{i,-k}$ varier dans l'échantillon.

Valeurs empiriques (MEM et AME). Les effets marginaux reportés ci-dessous doivent être interprétés comme des sensibilités locales des probabilités conditionnelles à une variation marginale des covariables, évaluées au point moyen (MEM) ou moyennées sur l'échantillon (AME).

MEM évalués en age = 49.152, female = 0.529, bmi = 27.960, exercise = 0.623 :

Outcome	age	female	bmi	exercise
1	0.000504	0.0054119	0.0029118	−0.0340787
2	0.0014308	0.0153651	0.0082671	−0.0967548
3	0.0013313	0.0142967	0.0076922	−0.0900266
4	−0.001274	−0.0136812	−0.0073611	0.0861513
5	−0.0019921	−0.0213924	−0.0115101	0.1347088

(p-values : `age`, `bmi`, `exercise` < 0.001 partout ; `female` ≈ 0.065–0.069 selon la modalité).

AME :

Outcome	age	female	bmi	exercise
1	0.0006447	0.0069235	0.0037252	−0.0435975
2	0.0012464	0.0133848	0.0072016	−0.0842843
3	0.0010526	0.0113041	0.0060821	−0.0711824
4	−0.0009408	−0.0101026	−0.0054357	0.0636166
5	−0.002003	−0.0215097	−0.0115732	0.1354477

(p-values : `age`, `bmi`, `exercise` < 0.001 partout ; `female` ≈ 0.065–0.068).

6. Résultats d'estimation : coefficients, seuils et interprétation

L'estimation Ordered Probit de `health` sur `age`, `female`, `bmi`, `exercise` est réalisée sur $N = 2009$.

Coefficients estimés.

$$\hat{\beta}_{\text{age}} = -0.008 \quad (\text{SE } 0.001;\ z = -6.11;\ p < 0.001;\ \text{IC95\% } [-0.010; -0.005]),$$

$$\hat{\beta}_{\text{female}} = -0.087 \quad (\text{SE } 0.047;\ z = -1.84;\ p = 0.065;\ \text{IC95\% } [-0.181; 0.005]),$$

$$\hat{\beta}_{\text{bmi}} = -0.047 \quad (\text{SE } 0.003;\ z = -12.26;\ p < 0.001;\ \text{IC95\% } [-0.054; -0.039]),$$

$$\hat{\beta}_{\text{exercise}} = 0.553 \quad (\text{SE } 0.050;\ z = 10.99;\ p < 0.001;\ \text{IC95\% } [0.454; 0.652]).$$

Seuils (cutpoints).

$$\hat{\kappa}_1 = -3.360\ (0.150), \quad \hat{\kappa}_2 = -2.450\ (0.142), \quad \hat{\kappa}_3 = -1.442\ (0.137), \quad \hat{\kappa}_4 = -0.432\ (0.135),$$

(les valeurs entre parenthèses sont les SE).

Interprétation (point clé). Dans un probit ordonné, le signe de $\hat{\beta}_k$ indique l'effet de la covariable sur la variable latente health* : un $\hat{\beta}_k < 0$ décale la distribution de health* vers le bas (moins bonne santé latente), un $\hat{\beta}_k > 0$ la décale vers le haut. En revanche, *ce signe ne se lit pas comme un « effet direct » sur une probabilité donnée* : l'effet sur $\mathbb{P}(\text{health} = j \mid x)$ dépend de j et de la position de $x'\beta$ relativement aux seuils, ce qui explique les effets marginaux de signes opposés selon les modalités (cf. MEM/AME).

Ici :

— `age` et `bmi` ont des coefficients négatifs et significatifs : ils diminuent la santé latente, ce qui augmente les probabilités des faibles modalités (1–3) et diminue celles des hautes modalités (4–5), conformément aux MEM/AME.

— `exercise` est positif et très significatif : il augmente la santé latente, réduit les probabilités des faibles modalités et augmente celles des hautes modalités.
— `female` est négatif mais seulement significatif au seuil de 10% (p=0.065) : l'effet estimé est plus incertain.

7. Probabilité prédite : modalité `health`=3 (good)

Pour la modalité 3 :

$$\mathbb{P}(\text{health}_i = 3 \mid x_i) = \Phi(\kappa_3 - x_i'\beta) - \Phi(\kappa_2 - x_i'\beta),$$

avec $x_i = (\text{age}_i, \text{female}_i, \text{bmi}_i, \text{exercise}_i)$, où female $= 1$ (femme) et exercise $= 1$ (yes). Pour age $= 50$, female $= 1$, bmi $= 30$, exercise $= 1$:

$$x_i'\beta = 50\,\beta_{\text{age}} + 1\,\beta_{\text{female}} + 30\,\beta_{\text{bmi}} + 1\,\beta_{\text{exercise}},$$

et la probabilité prédite est :

$$\widehat{\mathbb{P}}(\text{health} = 3 \mid \text{age} = 50,\ \text{female} = 1,\ \text{bmi} = 30,\ \text{exercise} = 1) = 0.329.$$

8. Qualité d'ajustement

— Log-vraisemblance du modèle : $\ell(\hat{\theta}) = -2715.268$; log-vraisemblance nulle : $\ell_0 = -2905.794$.
— Test du rapport de vraisemblance (LR) : $\chi^2(4) = 381.05$, $p < 0.001 \Rightarrow$ rejet du modèle nul (les covariables améliorent significativement l'ajustement).
— Pseudo-$R^2 = 0.065$.
— Critères d'information : AIC $= 5446.537$, BIC $= 5491.38$.

Bilan : le modèle est globalement significatif (LR), mais son pouvoir explicatif reste limité au sens du pseudo-R^2 ; l'évaluation se fait surtout par comparaison de spécifications via AIC/BIC.

Exercice 3 – Temperature Shocks and Economic Growth

Question 1. Fusion des bases et mise en forme panel

Après fusion des bases `growth.dta` (croissance g) et `temp.dta` (température $wtem$) et définition du panel :

$$\text{panel : } id \text{ (non équilibré)}, \qquad \text{temps : } year \in \{1950, \ldots, 2003\}.$$

Statistiques descriptives (après merge / `xtset`) :

$$g: \ \text{Obs} = 4967, \ \bar{g} = 1.507, \ s(g) = 5.837, \ \min = -70.290, \ \max = 64.095,$$

$$wtem: \ \text{Obs} = 6802, \ \overline{wtem} = 19.685, \ s(wtem) = 7.0716, \ \min = -3.582, \ \max = 29.583.$$

La différence d'effectifs (4967 pour g contre 6802 pour $wtem$) s'explique par des valeurs manquantes de g : $wtem$ est observée sur davantage d'années/pays que la croissance.

Question 2. Pays plus chauds ⇒ croissance plus faible ? (cross-section)

(a) Estimateur(s) et justification

Pour comparer des pays entre eux, on utilise une régression en coupe transversale sur moyennes par pays (estimation *between*) :

$$\overline{g}_i = \alpha + \beta\, \overline{wtem}_i + \varepsilon_i,$$

où $\overline{g}_i$ et $\overline{wtem}_i$ sont les moyennes (sur 1950–2003) pour le pays i. Cet estimateur identifie une relation *entre pays* (différences de niveaux moyens), mais reste exposé à l'omission de variables structurelles corrélées à $\overline{wtem}_i$.

(b) Résultats et commentaire

Régression : `reg mean_g mean_wtem` (N=127).

$$\widehat{\beta} = -0.100, \quad SE = 0.020, \quad t = -4.83, \quad p = 0.000,$$

$$IC_{95\%} = [-0.141; -0.059], \quad \widehat{\alpha} = 3.461, \quad SE = 0.435, \quad p = 0.000,$$

$$R^2 = 0.157.$$

Interprétation : en moyenne, une température plus élevée est associée à une croissance moyenne plus faible : +1 unité de $wtem$ est associée à -0.10 unité de g (différence *entre* pays), effet statistiquement significatif. Cette relation peut toutefois capturer des différences structurelles (institutions, géographie, niveau de développement) non contrôlées dans la coupe transversale.

Question 3. Effet des variations de température sur la croissance au sein *des pays*

(a) Estimateur(s) et justification

On cherche un effet identifié par la variation temporelle *intra-pays*. On utilise un modèle à effets fixes pays :

$$g_{it} = \alpha_i + \beta\, wtem_{it} + u_{it},$$

estimé par l'estimateur *within* (déviation à la moyenne pays), qui élimine les hétérogénéités inobservées invariantes dans le temps (α_i).

En complément, on peut regarder un modèle utilisant la première différence de température pour cibler un effet plus "court terme" :

$$g_{it} = \alpha_i + \beta\, \Delta wtem_{it} + u_{it}, \qquad \Delta wtem_{it} = wtem_{it} - wtem_{i,t-1}.$$

(b) Résultats et commentaire

(i) Effets fixes pays : `xtreg g c.wtem, fe`

$$\widehat{\beta} = -0.573, \quad SE = 0.153, \quad t = -3.74, \quad p = 0.000,$$
$$IC_{95\%} = [-0.874;\ -0.272], \quad N = 4967, \quad \text{groupes} = 127, \quad R^2_{\text{within}} = 0.0029.$$

Test de présence d'effets fixes pays (test de significativité des effets individuels) :

$$H_0 : \ \alpha_i = 0 \text{ pour tout } i \quad \text{(pas d'effets spécifiques pays ; pooled OLS suffirait)},$$
$$F(126, 4839) = 3.34, \quad p = 0.0000,$$

ce qui rejette H_0 et indique que les effets pays sont conjointement significatifs.

Interprétation : au sein d'un pays, une hausse de $wtem$ est associée à une baisse de g : $+1$ unité de $wtem \Rightarrow -0.57$ unité de g (effet intra-pays), statistiquement significatif.

(ii) Effets fixes pays avec variation (première différence) : `xtreg g D_wtem, fe`

$$\widehat{\beta} = -0.319, \quad SE = 0.151, \quad t = -2.11, \quad p = 0.035,$$
$$IC_{95\%} = [-0.616;\ -0.022], \quad R^2_{\text{within}} = 0.001.$$

Interprétation : une augmentation annuelle de la température ($\Delta wtem$) est associée à une baisse de la croissance la même année : $+1$ unité de $\Delta wtem \Rightarrow -0.32$ unité de g, significatif au seuil de 5%. L'effet estimé est plus faible en valeur absolue que dans la spécification en niveau, ce qui est cohérent avec une mesure plus "court terme" et plus bruitée de la variation climatique.

Question 4. Pooled vs Two-Way Fixed Effects (TWFE)

(a) Code

Code : voir do-file.

(b) Comparaison des résultats et explication

Pooled OLS : `reg g c.wtem`

$$\widehat{\beta}_{\text{pooled}} = -0.105, \quad SE = 0.011, \quad t = -9.00, \quad p = 0.000,$$
$$IC_{95\%} = [-0.128;\ -0.082], \quad N = 4967, \quad R^2 = 0.016.$$

TWFE : `xtreg g c.wtem i.year, fe` Modèle :

$$g_{it} = \alpha_i + \lambda_t + \beta\, wtem_{it} + u_{it},$$

où α_i sont des effets fixes pays et effets fixes année inclus (i.year).
Résultats (coefficient de $wtem$ uniquement) :

$$\widehat{\beta}_{\text{TWFE}} = -0.303, \quad SE = 0.183, \quad t = -1.65, \quad p = 0.099,$$
$$IC_{95\%} = [-0.664;\ 0.056], \quad N = 4967, \ \text{groupes} = 127, \quad R^2_{\text{within}} = 0.044.$$

Commentaire : le modèle pooled exploite surtout les différences *entre* pays et ignore (i) les hétérogénéités invariantes (α_i) et (ii) les chocs communs annuels (λ_t). Le TWFE contrôle ces deux sources d'omission, ce qui peut modifier fortement l'estimation (ici, coefficient plus négatif en valeur absolue), mais au prix d'une précision plus faible (écart-type plus grand) car l'identification repose uniquement sur la variation intra-pays *nettoyée* des effets année ; l'effet devient seulement significatif au seuil de 10% (p=0.099).

Question 5. Hétérogénéité géographique : interaction avec SSAF

(a) Code

Code : voir do-file.

(b) Interprétation des résultats

Spécification TWFE avec interaction :

$$g_{it} = \alpha_i + \lambda_t + \beta\, wtem_{it} + \delta\,(SSAF_i \times wtem_{it}) + u_{it},$$

où $SSAF_i$ est une dummy "Sub-Saharan Africa" (invariante dans le temps). En FE pays, le terme $SSAF_i$ seul est absorbé par α_i (colinéarité), ce qui est normal.

Résultats :

$$\widehat{\beta} = -0.111, \quad SE = 0.195, \quad p = 0.568,$$

$$\widehat{\delta} = -1.115, \quad SE = 0.382, \quad t = -2.92, \quad p = 0.004, \quad IC_{95\%} = [-1.864;\, -0.366].$$

Test de l'interaction : la statistique de Fisher est égale à 8.52, avec une p-value de 0.003, ce qui conduit au rejet de l'hypothèse nulle d'absence d'hétérogénéité d'effet.

Interprétation : hors SSAF ($SSAF_i = 0$), l'effet marginal estimé est $\widehat{\beta} = -0.111$ (non significatif). En SSAF ($SSAF_i = 1$), l'effet marginal devient :

$$\widehat{\beta} + \widehat{\delta} = -0.111 - 1.115 = -1.226,$$

ce qui indique un effet nettement plus négatif de la température sur la croissance en Afrique subsaharienne. La différence d'effet (l'interaction δ) est statistiquement significative (p=0.004), et le test conjoint confirme que l'effet dépend de la zone (p=0.003).

Question 6. Effets aléatoires vs effets fixes

(a) Comment trancher entre RE et FE ?

On considère :

$$g_{it} = \alpha + \beta\, wtem_{it} + \lambda_t + (\mu_i + u_{it}),$$

où μ_i capte les différences inobservées entre pays. Deux hypothèses :

$$\text{RE :}\ \operatorname{Corr}(\mu_i, wtem_{it}) = 0 \ \ (\forall t) \quad \Rightarrow \quad \text{RE consistant et plus efficient,}$$

$$\text{FE :}\ \operatorname{Corr}(\mu_i, wtem_{it}) \neq 0 \quad \Rightarrow \quad \text{RE biaisé, FE consistant.}$$

Le choix dépend donc de la plausibilité de la corrélation entre hétérogénéité pays (niveau de développement, institutions, structure productive, géographie) et température.

(b) Effets estimés sous chaque hypothèse (avec effets fixes année)

FE (TWFE) : `xtreg g c.wtem i.year, fe`

$$\widehat{\beta}_{FE} = -0.303, \quad p = 0.099.$$

RE : `xtreg g c.wtem i.year, re`

$$\widehat{\beta}_{RE} = -0.105, \quad SE = 0.020, \quad z = -5.11, \quad p = 0.000,$$

$$IC_{95\%} = [-0.145;\ -0.064].$$

Lecture : sous RE (absence de corrélation), l'effet est négatif et très significatif. Sous FE (corrélation potentielle), l'effet reste négatif mais moins précisément estimé (significatif au seuil de 10% seulement).

(c) Test(s) de discrimination et interprétation (Hausman)

Le test de Hausman compare FE et RE :

$$H_0 :\ \mathrm{Corr}(\mu_i, X_{it}) = 0 \quad \Rightarrow \quad RE \text{ consistant (et efficient).}$$

Ici, `hausman FE RE` renvoie un χ^2 négatif ($\chi^2(43) = -2.95$, message *"chi2<0"*), ce qui rend le test standard numériquement invalide (problème de $V_b - V_B$). On ne peut donc pas conclure statistiquement via Hausman. À défaut de test valide, on retient FE/TWFE pour la cohérence car une corrélation entre hétérogénéité pays et température est plausible (RE pouvant être biaisé).

Remarque sur les erreurs-types. Les erreurs-types ci-dessus supposent que les erreurs ne sont pas corrélées dans le temps ni entre pays. Or, avec des données macro en panel, il est plausible que les erreurs soient corrélées au sein d'un même pays d'une année à l'autre. Dans ce cas, des erreurs-types *clusterisées par pays* seraient plus adaptées. Les résultats doivent donc être interprétés avec cette réserve.

ANNEXE

Exercice 1

```
*****************************************************
* Exercice 1  Trust decision (Logit)
*****************************************************

clear all
set more off
version 16

*--- 0) Charger les donnes
use "binary_choices.dta", clear

*--- 1) Statistique descriptive de y (moyenne = proportion de 1)
summarize y

*--- 2) Estimation Logit : y sur r et p
logit y r p

*--- 3) Coefficients estims (affichs par logit)
* (rien  ajouter)

*--- 4) MEM (Marginal Effects at the Means) pour r et p
margins, dydx(r p) atmeans

*--- 5) AME (Average Marginal Effects) pour r et p
margins, dydx(r p)

*--- 6) Probabilit prdite pour (r=0, p=0.5)
margins, at(r=0 p=0.5) predict(pr)

*--- 7) Indicateurs de qualit dajustement
* Pseudo-R2, LR chi2, log-likelihood : affichs par logit

* Test global (LR) contre modle constant
logit y
estimates store m0

logit y r p
estimates store m1

lrtest m0 m1

estimates restore m1


* Table de classification (par dfaut seuil 0.5)
estat classification

* Goodness-of-fit (HosmerLemeshow)
estat gof, group(10) table

*****************************************************
* Fin
*****************************************************
```

Exercice 2

```
*****************************************************
* Exercice 2  Self-assessments of health status
*****************************************************

clear all
set more off
version 16

*--- 0) Charger les donnes
use "multiple_choices.dta", clear
```

```

*--- 1) Rendre femal binaire 0/1 (robuste : string ou numeric)
capture confirm numeric variable femal
if _rc {
    gen byte femal_num = .
    replace femal_num = 1 if inlist(lower(trim(femal)),"female","femal","f","woman","w")
    replace femal_num = 0 if inlist(lower(trim(femal)),"male","m","man")
    drop femal
    rename femal_num femal
}
else {
    quietly summarize femal, meanonly
    if r(min)==1 & r(max)==2 {
        gen byte femal01 = (femal==1)
        drop femal
        rename femal01 femal
    }
}

*--- 2) Rendre exercise binaire 0/1 (robuste : string yes/no ou numeric)
capture confirm numeric variable exercise
if _rc {
    gen byte exercise_num = .
    replace exercise_num = 1 if inlist(lower(trim(exercise)),"yes","y","1","true")
    replace exercise_num = 0 if inlist(lower(trim(exercise)),"no","n","0","false")
    drop exercise
    rename exercise_num exercise
}
else {
    quietly summarize exercise, meanonly
    if r(min)==1 & r(max)==2 {
        gen byte exercise01 = (exercise==1)
        drop exercise
        rename exercise01 exercise
    }
}

*--- 3) Descriptif de health
tab health, missing
summarize health

*--- 4) Estimation Ordered Probit
oprobit health age femal bmi exercise

*--- 5) Indicateurs d'ajustement (AIC/BIC) + LL/LR/pseudo-R2 dans la sortie oprobit
estat ic

*--- 6) MEM (Marginal Effects at the Means)  pour chaque modalit (1..5)
forvalues j = 1/5 {
    margins, dydx(age femal bmi exercise) atmeans predict(outcome(`j'))
}

*--- 7) AME (Average Marginal Effects)  pour chaque modalit (1..5)
forvalues j = 1/5 {
    margins, dydx(age femal bmi exercise) predict(outcome(`j'))
}

*--- 8) Probabilit prdite demande : P(health=3 | age=50, femal, bmi=30, exercise=yes)
*     Convention : femal=1 et exercise=1 correspondent  "femal" et "yes"
margins, at(age=50 femal=1 bmi=30 exercise=1) predict(outcome(3))

*****************************************************
* Fin
*****************************************************
```

Exercice 3

```
*****************************************************
* Exercice 3  Temperature Shocks and Economic Growth
*****************************************************

clear all
set more off
version 16

*--- 0) Vrifier que les fichiers sont dans le mme dossier que le .do
capture confirm file "growth.dta"
if _rc {
    di as error "Fichier growth.dta introuvable (mets-le dans le dossier courant)."
    exit 601
}
capture confirm file "temp.dta"
if _rc {
    di as error "Fichier temp.dta introuvable (mets-le dans le dossier courant)."
    exit 601
}

*****************************************************
* 1) Rendre chaque fichier unique sur (country_code, year)
*****************************************************

*-------------------------------*
* A) growth.dta : diagnostics + collapse si doublons
*-------------------------------*
use "growth.dta", clear

capture confirm variable country_code
if _rc {
    di as error "country_code introuvable dans growth.dta"
    describe
    exit 111
}
capture confirm variable year
if _rc {
    di as error "year introuvable dans growth.dta"
    describe
    exit 111
}

duplicates report country_code year
duplicates list country_code year in 1/50

capture isid country_code year
if _rc {
    local keepvars ""
    foreach v in g ki rgdpl gdpLCU gdpSHAREAG gdpWDIGDPAGR _MENA _SSAF _LAC _WEOFF _EECA _SEAS {
        capture confirm variable `v'
        if !_rc local keepvars "`keepvars' `v'"
    }
    if "`keepvars'"== "" {
        di as error "Aucune variable attendue dtecte dans growth.dta pour collapse."
        describe
        exit 111
    }
    collapse (mean) `keepvars', by(country_code year)
}
tempfile growth_u
save `growth_u', replace

*-------------------------------*
* B) temp.dta : diagnostics + collapse mto si doublons
*-------------------------------*
use "temp.dta", clear

capture confirm variable country_code
if _rc {
    di as error "country_code introuvable dans temp.dta"
    describe
```

```
    exit 111
}
capture confirm variable year
if _rc {
    di as error "year introuvable dans temp.dta"
    describe
    exit 111
}

duplicates report country_code year
duplicates list country_code year in 1/50

capture isid country_code year
if _rc {
    local metvars ""
    foreach v in wtem wpre wtem50 wpre50 {
        capture confirm variable `v'
        if !_rc local metvars "`metvars' `v'"
    }
    if "`metvars'"==""" {
        di as error "Aucune variable mto attendue dtecte dans temp.dta pour collapse."
        describe
        exit 111
    }
    collapse (mean) `metvars', by(country_code year)
}
tempfile temp_u
save `temp_u', replace

*******************************************************
* 2) Merge 1:1 (Q1) + gestion des non-matchs
*******************************************************
use `growth_u', clear
sort country_code year

merge 1:1 country_code year using `temp_u'
tab _merge
keep if _merge==3
drop _merge

*******************************************************
* 3) Crer identifiant numrique pour panel (country_code est string)
*******************************************************
capture confirm numeric variable country_code
if !_rc {
    gen long id = country_code
}
else {
    capture noisily encode country_code, gen(id)
    if _rc {
        egen long id = group(country_code)
    }
}
label var id "Country numeric id (from country_code)"

*******************************************************
* 4) Dtection/validation des variables g (croissance) et wtem (temprature)
*******************************************************
local tvar "year"

local gvar "g"
capture confirm variable `gvar'
if _rc {
    ds g* growth* *gr* *gdp*, has(type numeric)
    local gvar : word 1 of `r(varlist)'
}
if "`gvar'"==""" {
    di as error "Variable de croissance introuvable (attendue: g)."
    describe
    exit 111
}

local wvar "wtem"
```

```
capture confirm variable `wvar'
if _rc {
    ds wtem* *wtemp* *temp* *tem*, has(type numeric)
    local wvar : word 1 of `r(varlist)'
}
if "`wvar'"==""  {
    di as error "Variable temprature introuvable (attendue: wtem)."
    describe
    exit 111
}

*--- Assurer year numrique (utile pour i.year)
capture confirm numeric variable `tvar'
if _rc {
    quietly destring `tvar', replace ignore(" -_/")
    capture confirm numeric variable `tvar'
    if _rc {
        di as error "Variable temps non convertible en numrique: `tvar'"
        exit 109
    }
}


*******************************************************
*******************************************************
*******************************************************
*******************************************************
*******************************************************


*--- 1) Dclarer les donnes panel : xtset id year + descriptifs

xtset id `tvar'
xtdescribe

summarize `gvar' `wvar'
xtsum `gvar' `wvar'



*--- 2) Pays plus chauds -> croissance plus faible

preserve
collapse (mean) `gvar' `wvar', by(id country_code)
rename `gvar' mean_g
rename `wvar' mean_wtem
summarize mean_g mean_wtem
reg mean_g mean_wtem
restore


*--- 3) Variations de temprature -> croissance (panel)

xtreg `gvar' c.`wvar', fe

gen D_wtem = D.`wvar'
xtreg `gvar' D_wtem, fe

*--- 4) TWFE vs pooled

estimates clear

reg `gvar' c.`wvar'
estimates store pooled

xtreg `gvar' c.`wvar' i.`tvar', fe
estimates store twfe

* comparaison compatible (vite fmt(...) qui cause r(7) selon versions)
estimates table pooled twfe, b(%9.3f) se(%9.3f) stats(N r2)

*--- 5) Interaction avec SSAF (si existe)

```

```
local ssaf ""
foreach v in SSAF ssaf subsa subsahara ssa _SSAF {
    capture confirm variable `v'
    if !_rc {
        local ssaf "`v'"
        continue, break
    }
}

if "`ssaf'"==""  {
    di as error "SSAF (dummy Afrique subsaharienne) introuvable: interaction non estime."
}
else {
    xtreg `gvar' c.`wvar'##i.`ssaf' i.`tvar', fe
    test 1.`ssaf'#c.`wvar'
}

*--- 6) Random vs Fixed + Hausman

estimates clear

xtreg `gvar' c.`wvar' i.`tvar', fe
estimates store FE

xtreg `gvar' c.`wvar' i.`tvar', re
estimates store RE

capture noisily hausman FE RE
if _rc {
    capture noisily hausman FE RE, sigmamore
}

*****************************************************
* FIN
*****************************************************
```