LA NOTE D'ANALYSE

Analyse des facteurs influençant la réussite scolaire

Pourquoi certains élèves réussissent-ils, tandis que d'autres échouent ? L'explication courante est intuitive : *« il suffit d'étudier davantage »*. Pourtant, dès que l'on confronte cette idée aux données, elle perd en évidence.

À partir d'un échantillon de 395 élèves, cette analyse étudie l'impact réel de cinq facteurs : temps d'étude, absences, échecs antérieurs, sexe et situation amoureuse. L'approche combine statistiques descriptives et régression logistique afin d'isoler l'effet propre de chaque variable sur la probabilité de réussite.

Les résultats remettent en question plusieurs idées reçues. Étudier davantage ou être plus assidu ne garantit pas de meilleurs résultats. Leur influence existe, mais reste faible et souvent non significative : deux élèves peuvent consacrer le même temps au travail et obtenir des performances très différentes.

Le résultat le plus marqué concerne le parcours scolaire antérieur : un élève ayant déjà échoué présente statistiquement un risque plus élevé d'échouer à nouveau. La réussite apparaît moins comme un effort ponctuel que comme un processus accumulatif, construit sur plusieurs années.

Cette étude montre ainsi que pour comprendre la réussite scolaire, il faut regarder au-delà des comportements visibles et analyser les trajectoires.

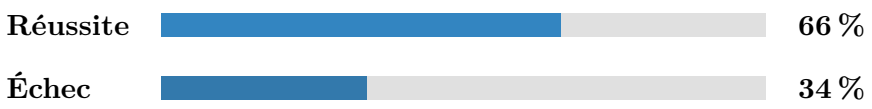

Répartition des élèves : réussite vs échec

Novembre 2025

Laury Hildevert Denecy
Antoine Jean

Introduction

La réussite scolaire constitue un enjeu central pour les systèmes éducatifs, car elle conditionne les trajectoires individuelles et, à plus long terme, le développement économique et social. Comprendre les facteurs associés à la réussite permet d'éclairer les politiques éducatives et les dispositifs d'accompagnement.

Plusieurs dimensions peuvent intervenir : comportements d'étude, assiduité, parcours scolaire antérieur et caractéristiques individuelles. L'objectif de ce rapport n'est pas de valider un modèle théorique précis, mais d'identifier, à partir des données, quels facteurs sont effectivement associés à la réussite. L'objectif est d'observer quels facteurs, dans notre jeu de données, semblent réellement associés à la réussite.

Ce rapport analyse un échantillon de 395 élèves (données du fichier MathesD4.xlsx) afin de déterminer quels éléments influencent le plus la probabilité de réussir.

Contexte et justification des variables

De nombreux travaux montrent que la réussite scolaire dépend de plusieurs dimensions : parcours antérieur, assiduité et implication dans le travail personnel. Le temps d'étude seul ne garantit pas la réussite ; la manière d'étudier et la régularité jouent un rôle important. Les absences peuvent affaiblir les résultats si elles entraînent une accumulation de retard. Enfin, un échec passé est souvent lié à une probabilité plus faible de réussite future.

Dans ce rapport, nous ne cherchons pas à tester ces théories mais simplement à analyser, sur notre jeu de données, l'impact de cinq variables : temps d'étude, absences, échecs antérieurs, sexe et situation amoureuse.

Table 1 – Hypothèses de travail par variable explicative

Variable	Hypothèse (H1)	Justification attendue
Temps d'étude	Plus le temps d'étude est élevé, plus la probabilité de réussite augmente.	La répétition et le volume de travail sont généralement liés à de meilleures performances scolaires.
Absences	Plus le nombre d'absences est important, plus la probabilité de réussite diminue.	L'absence en cours limite l'accès au contenu et à l'évaluation, ce qui peut entraîner des lacunes.
Échecs antérieurs	Avoir déjà échoué réduit fortement la probabilité de réussite actuelle.	Le passé scolaire influence l'engagement, la confiance et les acquis.
Sexe	La réussite diffère selon le sexe de l'élève.	Certains travaux identifient des écarts selon les contextes (méthodes, matières, attentes sociales).
Situation amoureuse	Les élèves en couple ont une probabilité de réussite plus faible.	La relation peut entraîner une baisse du temps consacré aux études.

Interprétation des résultats

Régression logistique multivariée — Odds Ratios (OR)

Variable	N	OR	IC 95 %	95% CI	p-value
Temps d'étude	395	1.19	0.89, 1.61	0.89, 1.61	0.2
Absences	395	0.99	0.96, 1.01	0.96, 1.01	0.3
Échecs antérieurs	395	0.38	0.27, 0.53	0.27, 0.53	**<0.001**
Sexe					**0.014**
F	202	—	—	—	
M	193	1.84	1.13, 3.01	1.13, 3.01	
En couple					0.3
no	263	—	—	—	
yes	132	0.79	0.49, 1.28	0.49, 1.28	

Abbreviations: CI = Confidence Interval, OR = Odds Ratio

Figure 1 – GT summary

Les résultats montrent que les étudiants qui consacrent davantage de temps au travail ont, en moyenne, de meilleures chances de réussir. À l'inverse, les absences répétées réduisent la probabilité de réussite. Les étudiants ayant déjà connu des échecs auparavant réussissent moins souvent, ce qui en fait le facteur le plus défavorable. Le sexe est également lié à la réussite, les hommes obtenant de meilleurs résultats que les femmes dans cet échantillon. En revanche, le fait d'être en couple ne semble pas avoir d'effet notable sur la réussite. Dans l'ensemble, la réussite apparaît surtout liée au parcours scolaire antérieur et à l'implication dans les études.

Performance et segmentation.

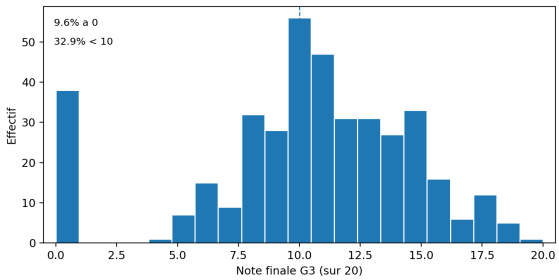

Figure 2 – Distribution et seuil de réussite (10/20)

La distribution des notes est centrée autour de l'intervalle 10–12, mais présente une dispersion non négligeable. Près d'un tiers des élèves (32.9 %) se situent sous le seuil de réussite fixé à 10, ce qui confère à la question de l'échec une portée concrète à l'échelle de la cohorte. La présence d'une proportion non marginale de notes nulles renforce l'hypothèse de situations de rupture de parcours ou d'absence d'évaluation.

Parcours antérieur et assiduité.

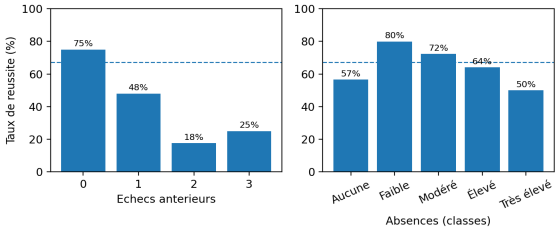

Figure 3 – Taux de réussite par échecs antérieurs et classes d'absences

Le parcours scolaire antérieur apparaît comme le principal marqueur de risque. Le taux de réussite atteint 75 % chez les élèves sans échec antérieur, mais chute dès lors qu'un échec est observé. Cette asymétrie suggère un mécanisme de cumul des difficultés lorsque celles-ci ne sont pas traitées en amont. L'absentéisme joue un rôle complémentaire : il est associé à une réussite plus faible dans les classes d'absences élevées, bien que son effet soit moins structurant que celui du parcours antérieur.

Temps d'étude et facteurs de contexte.

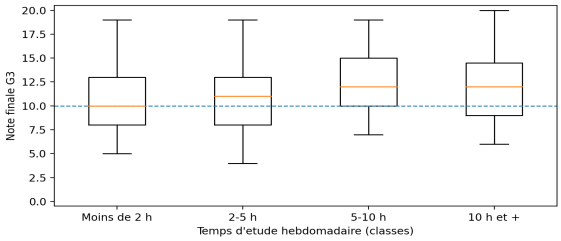

Figure 4 – Note finale G3 selon le temps d'étude

Tableau 2 — Taux de reussite par classes de temps d'etude

Temps d'etude	Effectif	Taux de reussite	Mediane (G3)
Moins de 2 h	105	64.8 %	10
2-5 h	198	64.6 %	11
5-10 h	65	75.4 %	12
10 h et +	27	74.1 %	12

Table 2 – Taux de réussite par classes de temps d'étude

Un temps d'étude plus élevé est associé à de meilleurs résultats, en particulier au-delà de 5 heures hebdomadaires, où le taux de réussite avoisine 75 %. Néanmoins, la forte superposition des distributions de notes entre classes de temps d'étude indique que le volume horaire ne constitue pas, à lui seul, un déterminant suffisant de la réussite. Les facteurs personnels (genre, situation amoureuse) présentent des écarts plus modestes et doivent être interprétés avec prudence, car ils peuvent refléter des différences de contexte non observées.

Discussion et mise en perspective des résultats

Dans l'ensemble, les résultats confirment que la réussite scolaire en mathématiques est majoritaire, mais que l'échec concerne une fraction substantielle de la cohorte. La dispersion initiale des performances rend indispensable une lecture par profils, laquelle met en évidence le rôle central du parcours antérieur, puis l'effet complémentaire de l'assiduité et du travail personnel.

Ces constats suggèrent que les politiques ou dispositifs d'accompagnement gagneraient à cibler prioritairement les élèves ayant déjà connu des difficultés, plutôt qu'à se limiter à des interventions uniformes sur l'ensemble de la population scolaire. Le temps de travail apparaît comme un levier nécessaire mais non suffisant, ce qui renvoie à la question de la qualité des méthodes d'apprentissage et de la consolidation des acquis de base.

Une extension naturelle de cette analyse consisterait à inscrire ces relations dans un cadre multivarié, afin de contrôler simultanément l'ensemble des facteurs observés. À plus long terme, une approche longitudinale, reposant sur des comparaisons avant/après ou sur le suivi de cohortes, permettrait de distinguer ce qui relève de déterminants structurels de ce qui est effectivement actionnable par des politiques éducatives ciblées.

ANNEXES

Code R

Main

```r
# Nettoyage de l'environnement et de la console
clearAll()  # (fonction perso dans .Rprofile : supprime objets, nettoie console, libère mémoire)



# ---- 0) Packages ----

# Chargement des bibliothèques nécessaires
library(readxl)    # importer des fichiers Excel
library(dplyr)     # manipuler des données (mutate, select, filter, etc.)
library(ggplot2)   # graphiques
library(janitor)   # nettoyage automatique des noms de colonnes
library(broom)     # formatage des sorties de modèles statistiques
library(gtsummary) # tableaux descriptifs et tests



# ---- 1 ) Import & préparation ----

# Import du fichier Excel et nettoyage des noms de variables
df <- read_excel("C:/Users/tonio/Bureau/StatM1/Données/Mathes_D4.xlsx") |> clean_names()

# Transformation des variables : passage en facteurs ou numériques
df <- df |>
    mutate(
        pass     = factor(pass, levels = c("fail","pass")),  # variable binaire ordonnée
        sex      = factor(sex),                              # variable qualitative
        romantic = factor(romantic, levels = c("no","yes")), # variable binaire
        studytime = as.numeric(studytime),                   # heures d'étude → numérique
        absences  = as.numeric(absences),                    # absences → numérique
        failures  = as.numeric(failures)                     # échecs → numérique
    )

# Vérification des valeurs manquantes
colSums(is.na(df))  # affiche le nombre de NA par colonne



# ---- 2) Descriptif global ----

# Nombre d'observations
nrow(df)

# Effectifs et pourcentages de réussite/échec
table(df$pass)
prop.table(table(df$pass))

# Statistiques descriptives des principales variables quantitatives
summary(df[,c("studytime","absences","failures")])

prop_tab <- function(x, y) {
    tab <- prop.table(table(x, y), margin = 1)  # pourcentages par ligne
    round(100*tab,1)                            # arrondi à 1 décimale
}

# Tableau descriptif global
df %>%
    select(pass, studytime, absences, failures, sex, romantic) %>%
    tbl_summary(
        by = pass,
        statistic = list(
            all_continuous() ~ "{mean} ± {sd}",
            all_categorical() ~ "{n} ({p}%)"
        ),
        missing = "no"
    ) %>%
    modify_header(label = "**Variable**") %>%
```

```r
    bold_labels()


# ---- 3) Univarié : quanti -> pass ----

# Fonction pour analyser une variable quantitative selon la réussite
analyse_quanti <- function(varname){
    v <- df[[varname]]                          # extraction de la variable
    # Test de Student pour comparer les moyennes entre groupes (fail/pass)
    tt <- t.test(v ~ df$pass)
    # Modèle logistique simple pour estimer la probabilité de réussite selon la variable
    fit <- glm(pass ~ v, data = df, family = binomial)
    # Calcul des odds-ratios et intervalles de confiance
    or  <- exp(cbind(OR = coef(fit), confint.default(fit)))
    # Retourne les résultats sous forme de liste
    list(t_test = tt, logit_or = or)
}

# Application de la fonction à plusieurs variables quantitatives
res_studytime <- analyse_quanti("studytime")
res_absences  <- analyse_quanti("absences")
res_failures  <- analyse_quanti("failures")

# Graphiques en boxplot + export en image PNG
#Temps de travail
ggplot(df, aes(x = pass, y = studytime)) +
    geom_boxplot(fill = "#8FD694") +
    labs(title="Temps d'etude selon la reussite", x="Reussite", y="Temps d'etude hebdomadaire")
t.test(df$studytime ~ df$pass)

ggsave("plot_studytime_box.png", width=5, height=4, dpi=300)

#Absences
ggplot(df, aes(x = pass, y = absences)) +
    geom_boxplot(fill = "#9ecae1") +
    labs(title="Absences selon la reussite", x="Reussite", y="Nombre d'absences")
t.test(df$absences ~ df$pass)

ggsave("plot_absences_box.png", width=5, height=4, dpi=300)

#Echec
ggplot(df, aes(x = pass, y = failures)) +
    geom_boxplot(fill = "#fdae6b") +
    labs(title="echecs precedents et reussite", x="Reussite", y="Nombre d'echecs")
t.test(df$failures ~ df$pass)

ggsave("plot_failures_box.png", width=5, height=4, dpi=300)



# ---- 4) Univarié : quali -> pass ----

# Analyse de variables qualitatives (catégorielles)

# --- Variable sex ---
tab_sex <- table(df$sex, df$pass); tab_sex          # tableau de contingence
chisq.test(tab_sex)                                 # test du Chi² (ou fisher.test si effectifs faibles)

# Graphique en barres empilées (proportions par sexe)
ggplot(df, aes(x = sex, fill = pass)) +
    geom_bar(position = "fill") +
    labs(title="Taux de reussite par sexe", y="Proportion")
ggsave("plot_sex_pass.png", width=5, height=4, dpi=300)

# --- Variable romantic ---
tab_rom <- table(df$romantic, df$pass); tab_rom     # tableau de contingence
chisq.test(tab_rom)                                 # test du Chi² pour indépendance

# Graphique du taux de réussite selon la vie romantique
ggplot(df, aes(x = romantic, fill = pass)) +
    geom_bar(position = "fill") +
    labs(title="Taux de reussite selon la vie amoureuse", y="Proportion")
ggsave("plot_romantic_pass.png", width=5, height=4, dpi=300)
```

```r
# ---- 5) Modèle logistique multivarié ----

# Modèle logistique multivarié (toutes les variables explicatives ensemble)
fit_multi <- glm(pass ~ studytime + absences + failures + sex + romantic,
                 data = df, family = binomial)

# Résumé du modèle (coefficients, significativité, etc.)
summary(fit_multi)

# Calcul des odds-ratios et intervalles de confiance pour interprétation
exp(cbind(OR = coef(fit_multi), confint.default(fit_multi)))



# ---- Rapport ----
#Ajout de OR (via GPT)

# 1) OR + IC, nettoyage + ordre des variables
or <- tidy(fit_multi, exponentiate = TRUE, conf.int = TRUE) %>%
    filter(term != "(Intercept)") %>%
    mutate(
        var = recode(term,
                     studytime   = "Temps d'étude",
                     absences    = "Absences",
                     failures    = "Échecs antérieurs",
                     sexM        = "Sexe : garçon (vs fille)",
                     romanticyes = "En couple (vs non)"
        ),
        # significatif si l'IC95% n'inclut pas 1
        sig = if_else(conf.low > 1 | conf.high < 1, "Significatif", "Non significatif"),
        # ordre d'affichage (haut → bas)
        var = factor(var, levels = c(
            "Échecs antérieurs", "Absences", "Temps d'étude",
            "Sexe : garçon (vs fille)", "En couple (vs non)"
        ))
    )

# 2) Forest plot sobre, style rapport
ggplot(or, aes(x = estimate, y = var, color = sig)) +
    geom_errorbar(aes(xmin = conf.low, xmax = conf.high),
                  width = 0.18, linewidth = 1) +
    geom_point(size = 3) +
    geom_vline(xintercept = 1, linetype = "dashed", linewidth = 0.7, alpha = 0.8) +
    scale_color_manual(values = c("Significatif" = "#0067B1", "Non significatif" = "grey50"), name = NULL) +
    labs(title = "Effet des variables sur la probabilité de réussite",
         x = "Odds Ratio (OR)", y = NULL) +
    theme_minimal(base_size = 12) +
    theme(
        legend.position = "top",
        panel.grid.minor = element_blank(),
        panel.grid.major.y = element_blank(),
        axis.text.y = element_text(size = 11),
        plot.title = element_text(face = "bold")
    )

# Export (optionnel)
ggsave("forest_logit_sobre.png", width = 6.2, height = 6.4, dpi = 300)
```

Fonction clearAll dans le .Rprofile

```r
# ---- FONCTION CLEARALL ----
clearAll <- function() {
    rm(list = ls(envir = .GlobalEnv), envir = .GlobalEnv)  # supprime tous les objets
    cat("\014")  # nettoie la console
    gc()  # libère la mémoire
    message("Workspace et console nettoyés")
}
```

```
message("Profil R chargé avec succès")
```