Analyse multivariée des indicateurs de développement durable – UE (2020)

Le développement durable constitue aujourd'hui un cadre central pour comparer les situations économiques et sociales des pays de l'Union européenne. Il repose sur une approche globale, intégrant à la fois des dimensions sociales, économiques et environnementales, telles qu'elles sont suivies dans le cadre des objectifs de développement durable de l'Agenda 2030. Pour l'année 2020, ces indicateurs offrent une vision d'ensemble des situations nationales, mais présentent une forte hétérogénéité, tant par leur nature que par leurs unités de mesure.

La lecture directe de ces indicateurs demeure toutefois délicate. Leur nombre élevé et les relations étroites existant entre certaines variables rendent difficile une interprétation synthétique des différences entre pays.

Dans ce contexte, le recours à des méthodes d'analyse multivariée apparaît particulièrement adapté. Les méthodes factorielles permettent de résumer l'information contenue dans l'ensemble des indicateurs et de mettre en évidence des structures communes, tandis que les méthodes de classification visent à regrouper les pays selon des profils proches. L'analyse discriminante vient compléter cette démarche en évaluant la cohérence et la séparation des groupes obtenus.

Le rapport est structuré de la manière suivante. La première partie présente les données et les variables mobilisées. Une analyse descriptive et des corrélations est ensuite menée. L'analyse en composantes principales permet de synthétiser l'information, avant la construction d'une typologie des pays par classification hiérarchique, enfin examinée à l'aide d'une analyse discriminante.

ANALYSE DE DONNEES

DECEMBRE 2025

Laury Hildevert Denecy
Antoine Jean

Table des matières

1 Données et variables **2**
- 1.1 *Source et périmètre* . . . 2
- 1.2 *Unité statistique et taille de l'échantillon* . . . 2
- 1.3 *Structure et catégories des variables* . . . 2
- 1.4 *Orientation des variables et préparation des données* . . . 2

2 Analyse descriptive et corrélations **3**
- 2.1 *Dispersion des indicateurs et hétérogénéité entre pays* . . . 3
- 2.2 *Structure des corrélations entre les variables* . . . 4
- 2.3 *Justification du recours à une analyse en composantes principales* . . . 5

3 Analyse en composantes principales **5**
- 3.1 *Objectif et principe de l'ACP* . . . 5
- 3.2 *Choix du nombre d'axes retenus* . . . 5
- 3.3 *Interprétation des deux premiers axes à partir des variables* . . . 6
- 3.4 *Lecture du plan factoriel des pays (axes 1 et 2)* . . . 7
- 3.5 *Transition : apport de l'ACP pour une typologie* . . . 8

4 Typologie des pays **8**
- 4.1 *Méthode de classification* . . . 8
- 4.2 *Choix du nombre de classes* . . . 9
- 4.3 *Description synthétique des profils de classes* . . . 9
- 4.4 *Mise en relation avec l'analyse en composantes principales* . . . 10
- 4.5 *Transition vers l'analyse discriminante* . . . 11

5 Analyse discriminante : validation de la typologie **11**

6 Conclusion **13**

7 Annexe **14**
- 7.1 *code* . . . 14
  - 7.1.1 00_start.sas . . . 14
  - 7.1.2 01_clean.sas . . . 14
  - 7.1.3 02_descriptif_corr.sas . . . 17
  - 7.1.4 03_acp.sas . . . 18
  - 7.1.5 04_cluster.sas . . . 19
  - 7.1.6 05_discriminante.sas . . . 21

1 Données et variables

1.1 *Source et périmètre*

Les données constituent une *coupe transversale* pour l'année 2020 et portent sur des indicateurs phares de développement durable couvrant trois domaines (social, économique, environnemental), mobilisés dans le cadre du suivi des objectifs de développement durable (Agenda 2030). Elles sont exploitées dans SAS Studio via une table de travail dédiée au projet.

1.2 *Unité statistique et taille de l'échantillon*

L'unité statistique est le **pays**. L'identifiant est la variable textuelle `Pays`. Le contrôle effectué lors du nettoyage indique un passage de **29** observations avant nettoyage à **27** observations après suppression des lignes vides ou non exploitables, conduisant à un échantillon final de 27 pays.

1.3 *Structure et catégories des variables*

Le jeu de données nettoyé comporte **17 variables** : une variable d'identification (`Pays`, type caractère) et **16 variables quantitatives** (type numérique). Les libellés (labels) des variables sont conservés afin de documenter précisément le contenu des indicateurs, notamment leurs unités (pourcentages, tonnes équivalent CO_2 par habitant, ou échelles de réponse).

La structuration des variables est formalisée via un dictionnaire qui affecte à chaque indicateur un *domaine* (social, économique, environnemental) ainsi qu'un champ *sens* (orientation « plus élevé = favorable/défavorable ») destiné aux traitements ultérieurs.

1.4 *Orientation des variables et préparation des données*

Le champ `sens` du dictionnaire précise l'orientation retenue pour chaque indicateur : `PLUS=BON` lorsque des valeurs plus élevées sont considérées comme favorables, et `PLUS=MAUVAIS` dans le cas inverse. Certains indicateurs sont explicitement marqués `a_revoir`, signalant la nécessité d'une vérification préalable de leur classement ou de leur orientation avant exploitation analytique.

Le script de préparation assure la vérification de la variable `Pays` comme identifiant, la suppression des observations non exploitables (lignes vides) et la constitution du dictionnaire de variables. Une table de travail standardisée est également produite afin de disposer, si nécessaire, d'une version des indicateurs transformés garantissant la comparabilité des échelles dans le cadre des méthodes d'analyse multivariée.

Table 1 – *Variables retenues, domaine d'analyse et sens d'interprétation*

Variable	Domaine	Sens
Espérance de vie en bonne santé (femmes)	Social	Plus = meilleur
Espérance de vie en bonne santé (hommes)	Social	Plus = meilleur
Satisfaction dans la vie	Social	Plus = meilleur
Dispersion des revenus	Social	Plus = moins favorable
Pauvreté en conditions de vie	Social	Plus = moins favorable
Sorties précoces du système scolaire (18–24 ans)	Social	Plus = moins favorable
Taux d'emploi des 15–64 ans	Social	Plus = meilleur
Taux de chômage des 15–24 ans	Social	Plus = moins favorable
Taux de chômage des 15–74 ans	Social	Plus = moins favorable
Dépenses de R&D (% du PIB)	Économique	Plus = meilleur
Dette publique (% du PIB)	Économique	Plus = moins favorable
Endettement des ménages (% du PIB)	Économique	Plus = moins favorable
Endettement des sociétés non financières (% du PIB)	Économique	Plus = moins favorable
Taux de croissance du PIB réel par tête	Économique	Plus = meilleur
Émissions de gaz à effet de serre par habitant	Environnemental	Plus = moins favorable
Artificialisation des sols (% du territoire)	Environnemental	Plus = moins favorable

2 Analyse descriptive et corrélations

2.1 *Dispersion des indicateurs et hétérogénéité entre pays*

L'analyse descriptive porte sur seize indicateurs couvrant les dimensions sociale, économique et environnementale du développement durable, observés pour l'ensemble des pays de l'Union européenne en 2020. Les statistiques issues de l'étape descriptive mettent en évidence une hétérogénéité marquée entre pays, avec des niveaux de dispersion très contrastés selon les variables considérées.

Certaines variables présentent une variabilité relativement limitée. C'est notamment le cas des indicateurs de santé et de bien-être, tels que l'espérance de vie en bonne santé (pour les femmes comme pour les hommes) ou la satisfaction dans la vie, dont les écarts-types et les amplitudes restent modérés à l'échelle européenne. Ces indicateurs traduisent des niveaux relativement homogènes entre pays, malgré des différences persistantes.

À l'inverse, plusieurs variables socio-économiques se caractérisent par une dispersion élevée. Les indicateurs liés aux conditions de vie et au marché du travail, comme la pauvreté en conditions de vie ou le chômage des jeunes, présentent des écarts importants entre pays. De même, les variables d'endettement, en particulier la dette publique et l'endettement des sociétés non financières, affichent des amplitudes très larges, révélant des structures économiques nationales fortement différenciées.

Les indicateurs environnementaux occupent une position intermédiaire : les émissions de gaz à effet de serre par habitant et le taux d'artificialisation des sols présentent une variabilité non négligeable, sans toutefois atteindre les niveaux

observés pour certaines variables financières ou sociales. Enfin, la croissance du PIB réel par habitant en 2020 apparaît relativement volatile, ce qui reflète en partie le caractère conjoncturel de cette variable sur une année marquée par des chocs macroéconomiques importants.

Table 2 – *Statistiques descriptives des indicateurs de développement durable (UE, 2020)*

Variable	Moyenne	Écart-type	Min	Max
Espérance de vie en bonne santé (femmes)	62.94	4.66	54.30	72.70
Espérance de vie en bonne santé (hommes)	61.83	4.66	52.60	72.80
Satisfaction dans la vie	7.21	0.64	5.40	8.10
Dispersion des revenus	4.76	1.23	3.00	7.50
Pauvreté en conditions de vie (%)	11.27	8.18	3.50	34.50
Sorties précoces du système scolaire (%)	8.10	3.31	2.30	15.60
Taux d'emploi des 15–64 ans (%)	71.54	5.40	60.10	81.80
Dépenses de R&D (% du PIB)	1.74	0.89	0.50	3.40
Dette publique (% du PIB)	67.82	38.04	18.40	171.30
Endettement des ménages (% du PIB)	50.58	24.70	15.80	124.60
Endettement des sociétés non financières (% du PIB)	83.74	51.66	30.30	274.80
Émissions de GES par habitant (t éq. CO_2)	8.02	2.40	4.10	14.70
Artificialisation des sols (%)	5.61	5.18	1.70	27.50
Taux de chômage 15–24 ans (%)	15.47	6.68	5.90	31.40
Taux de chômage 15–74 ans (%)	5.76	2.55	2.30	12.90
Croissance du PIB réel par tête (%)	3.64	2.55	-1.40	9.90

2.2 *Structure des corrélations entre les variables*

L'examen de la matrice de corrélations met en évidence l'existence de plusieurs ensembles de variables fortement associées, suggérant des dimensions latentes communes. Un premier ensemble clairement identifié concerne les indicateurs de santé : l'espérance de vie en bonne santé des femmes et des hommes est très fortement corrélée, traduisant une redondance élevée de l'information portée par ces deux variables.

Un second ensemble regroupe des variables relatives aux inégalités et aux conditions de vie. La dispersion des revenus est fortement corrélée à la pauvreté en conditions de vie, tandis que ces deux indicateurs sont négativement associés à la satisfaction dans la vie. Cette structure fait apparaître une opposition statistique marquée entre des variables décrivant des situations de précarité et un indicateur de bien-être subjectif.

Un troisième ensemble concerne le marché du travail. Le chômage des jeunes et le chômage total sont très fortement corrélés entre eux, et tous deux présentent une corrélation négative élevée avec le taux d'emploi. Ces relations traduisent l'existence d'une dimension commune liée à la tension du marché du travail, avec une information partiellement redondante entre ces variables.

D'autres corrélations notables apparaissent entre les variables économiques et sociales. Les dépenses de recherche et développement sont positivement associées à

la satisfaction dans la vie et négativement corrélées aux indicateurs d'inégalités et de pauvreté. Par ailleurs, les niveaux d'endettement des ménages et des sociétés non financières sont positivement corrélés, et l'endettement des sociétés présente également une association positive avec les émissions de gaz à effet de serre par habitant, suggérant des liens statistiques entre structure productive et pression environnementale.

À l'inverse, certaines variables, comme la croissance du PIB réel par habitant, présentent des corrélations plus faibles avec l'ensemble des autres indicateurs. Cette relative indépendance statistique est cohérente avec le caractère plus conjoncturel de cette variable à l'horizon annuel considéré.

2.3 *Justification du recours à une analyse en composantes principales*

L'analyse descriptive et l'étude des corrélations mettent en évidence deux éléments structurants : d'une part, une hétérogénéité importante des niveaux et des dispersions selon les indicateurs, et d'autre part, l'existence de corrélations élevées entre plusieurs groupes de variables. Cette configuration révèle une redondance significative de l'information et un risque de colinéarité dans une analyse multivariée directe.

Dans ce contexte, le recours à une analyse en composantes principales apparaît pertinent afin de synthétiser l'information contenue dans les variables initiales en un nombre réduit d'axes factoriels. L'ACP permettra d'identifier des dimensions latentes structurant les données, de résumer les principales oppositions statistiques entre pays et de faciliter l'interprétation globale des profils multivariés, tout en préparant la construction d'une typologie cohérente des pays de l'Union européenne.

3 Analyse en composantes principales

3.1 *Objectif et principe de l'ACP*

L'analyse en composantes principales (ACP) vise à synthétiser l'information contenue dans un ensemble d'indicateurs corrélés, en construisant un nombre réduit d'axes factoriels orthogonaux. Dans cette étude, l'ACP est appliquée à 16 variables décrivant des dimensions sociales, économiques et environnementales du développement durable pour 27 pays de l'Union européenne (année 2020). La démarche permet de résumer la structure des corrélations observée lors de l'analyse descriptive, d'identifier quelques gradients principaux de différenciation entre pays, et de fournir une base de scores factoriels exploitables ensuite pour une typologie (classification).

3.2 *Choix du nombre d'axes retenus*

Les valeurs propres issues de l'ACP sur la matrice de corrélation indiquent que les deux premiers axes concentrent une part substantielle, mais non majoritaire, de la variabilité totale. Le premier axe explique 29,12% de la variance, et le second

18,38%, soit un cumul de 47,50% sur le plan factoriel (1,2). Les axes suivants contribuent de manière décroissante (par exemple, l'axe 3 porte le cumul à 59,92%). Au regard du critère de Kaiser (valeurs propres strictement supérieures à 1), cinq composantes sont éligibles à une interprétation et/ou à une utilisation en synthèse, le cumul atteignant alors 78,06% ; à partir de l'axe 6, la valeur propre devient inférieure à 1, ce qui suggère un apport informationnel plus limité.

Dans la suite, l'analyse se concentre sur les deux premiers axes, car ils sont ceux qui structurent le plus nettement la représentation graphique et permettent une lecture globale des oppositions. Il est toutefois important de noter que le plan (1,2) ne résume qu'environ la moitié de la variance totale : une éventuelle typologie pourra mobiliser un nombre plus élevé d'axes afin de limiter la perte d'information.

3.3 *Interprétation des deux premiers axes à partir des variables*

L'interprétation des axes repose sur la position des variables sur le cercle des corrélations et sur la cohérence avec la matrice de corrélations observée précédemment. L'objectif n'est pas de « nommer » de manière définitive les axes, mais d'identifier les variables qui y contribuent le plus et la logique d'opposition qu'ils induisent.

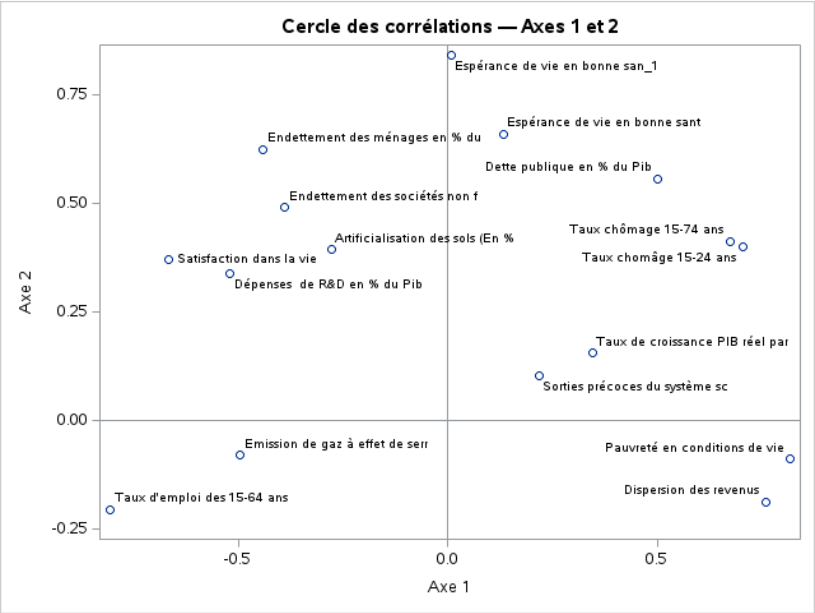

Figure 1 – *Cercle des corrélations – axes 1 et 2*

Sur l'axe 1, une première structuration oppose clairement, du côté des coordonnées positives, des indicateurs de fragilités socio-économiques (dispersion des revenus, pauvreté en conditions de vie, chômage des 15–24 ans, chômage des 15–74 ans, ainsi que la dette publique). À l'inverse, le côté négatif de l'axe 1 regroupe principalement le taux d'emploi des 15–64 ans, la satisfaction dans la vie, les dépenses de R&D, ainsi que les indicateurs d'endettement privé (ménages et sociétés non financières). Cette opposition est cohérente avec la structure de corrélations : la pauvreté et la dispersion des revenus sont fortement corrélées positivement entre

elles, et toutes deux corrélées négativement avec la satisfaction dans la vie et les dépenses de R&D ; de même, les taux de chômage sont fortement liés entre eux, et s'opposent au taux d'emploi. L'axe 1 peut ainsi être lu comme un gradient synthétique reliant un ensemble « inégalités/pauvreté/chômage » à un ensemble « emploi/satisfaction/effort de R&D », sans préjuger d'une causalité.

L'axe 2 est principalement structuré par les variables d'espérance de vie en bonne santé (femmes et hommes), très proches sur le cercle et cohérentes avec leur forte corrélation bilatérale. Ces variables se projettent nettement du côté positif de l'axe 2, en compagnie de plusieurs indicateurs macro-financiers (notamment la dette publique et l'endettement des ménages, et dans une moindre mesure l'endettement des sociétés), ainsi que des taux de chômage qui apparaissent également du côté positif. À l'opposé (coordonnées négatives sur l'axe 2), on observe plutôt la dispersion des revenus et la pauvreté en conditions de vie, et, plus près de l'origine, certaines variables comme le taux d'emploi et les émissions de gaz à effet de serre (qui se distinguent surtout par une projection moins marquée sur cet axe). En pratique, l'axe 2 peut être interprété comme un second gradient de différenciation, fortement « porté » par la dimension santé (espérance de vie en bonne santé), et articulé avec une composante de structure économique/financière ; cette lecture doit rester prudente, car plusieurs variables (hors espérance de vie) présentent des projections plus modestes que sur l'axe 1.

3.4 *Lecture du plan factoriel des pays (axes 1 et 2)*

La projection des pays sur le plan (1,2) met en évidence des regroupements et des positions extrêmes qui reflètent directement les oppositions décrites ci-dessus.

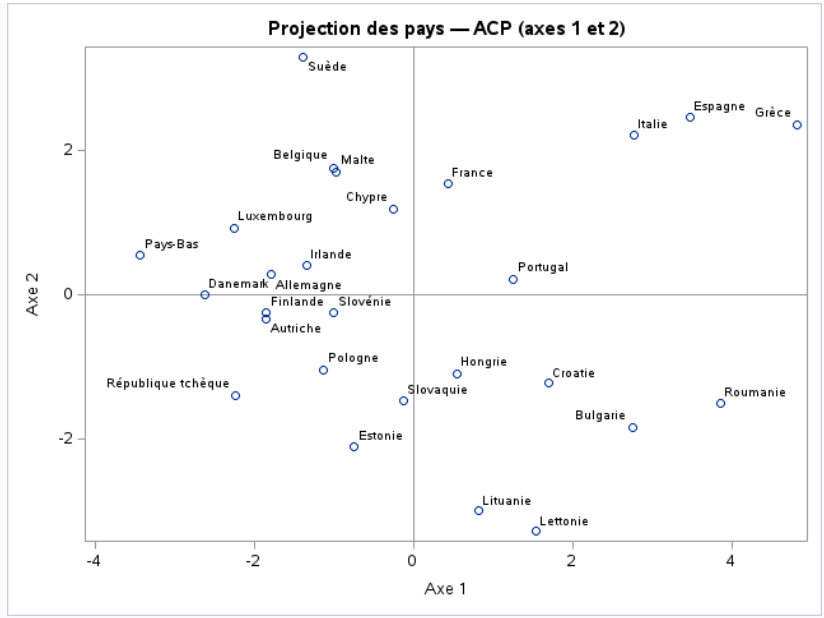

Figure 2 – *Projection des pays – axes 1 et 2*

Sur l'axe 1, les pays situés à droite du plan correspondent aux profils présentant relativement plus de caractéristiques associées positivement à cet axe (notamment

chômage, pauvreté, dispersion des revenus et dette publique), tandis que ceux situés à gauche se caractérisent davantage par les variables corrélées négativement (taux d'emploi, satisfaction dans la vie, dépenses de R&D et endettement privé). Sans commenter l'ensemble des pays, on peut signaler que certains apparaissent plus extrêmes sur l'axe 1 (par exemple un pays très à gauche et plusieurs pays très à droite), ce qui en fait des points de référence pour la lecture des oppositions, sans que cela implique un jugement de valeur.

Sur l'axe 2, la dispersion verticale est notamment influencée par l'espérance de vie en bonne santé : les pays en haut du plan sont associés à des niveaux relativement plus élevés de cette dimension (et, selon les cas, à des niveaux plus élevés des variables également du même côté de l'axe 2), tandis que les pays en bas se situent plutôt du côté opposé. Là encore, quelques pays se distinguent par des positions très marquées (un pays nettement en haut du plan, et plusieurs pays nettement en bas), suggérant une hétérogénéité importante sur ce second gradient.

Au total, le plan factoriel (1,2) met en évidence au moins quatre configurations-types (quadrants) :(i) des pays à la fois à droite et en haut, cumulant des valeurs élevées pour les variables corrélées positivement aux deux axes ; (ii) des pays à droite mais en bas, plus alignés sur l'axe 1 que sur l'axe 2 ; (iii) des pays à gauche et en haut, caractérisés par les variables du côté négatif de l'axe 1 mais positif de l'axe 2 ; (iv) des pays à gauche et en bas, plus proches des valeurs négatives des deux axes. Cette structuration justifie l'étape suivante de classification, qui permettra de formaliser ces proximités.

3.5 *Transition : apport de l'ACP pour une typologie*

L'ACP fournit une représentation synthétique des données et des scores factoriels qui résument l'information multidimensionnelle. Dans la perspective d'une typologie des pays, ces scores constituent des variables de synthèse pertinentes : ils réduisent la redondance liée aux corrélations entre indicateurs et offrent une base géométrique adaptée aux méthodes de classification. Étant donné que le plan (1,2) ne résume qu'environ 47,5% de la variance, la classification pourra s'appuyer sur plusieurs axes (par exemple ceux associés aux valeurs propres supérieures à 1), afin de conserver une part plus importante de l'information tout en limitant le bruit des composantes de faible inertie.

4 Typologie des pays

4.1 *Méthode de classification*

La typologie est construite à partir des 27 pays décrits par 16 indicateurs observés en 2020. Afin d'éviter qu'un indicateur domine la classification en raison de son unité de mesure ou de sa variance, la classification est réalisée sur des données standardisées (centrées et réduites). Cette étape garantit une contribution comparable de chaque variable au calcul des distances.

La méthode retenue est une classification hiérarchique ascendante (CAH), mise en œuvre sous SAS via la procédure `PROC CLUSTER`, en utilisant le critère de Ward.

Ce critère repose sur la minimisation de l'augmentation de l'inertie intra-classe à chaque fusion, ce qui conduit à la formation de groupes aussi homogènes que possible.

4.2 *Choix du nombre de classes*

Le choix du nombre de classes repose sur une analyse conjointe du dendrogramme et des statistiques de regroupement fournies par la procédure de classification. L'examen du dendrogramme met en évidence une rupture plus marquée lorsque la partition passe de trois à deux classes, suggérant une perte substantielle d'information à ce stade.

Les indicateurs quantitatifs confirment cette lecture graphique : le coefficient de détermination global (R^2) diminue sensiblement lorsque l'on réduit le nombre de classes de trois à deux, et le R^2 semi-partiel associé à cette fusion est plus élevé que celui observé lors des regroupements précédents. Ces éléments conduisent à retenir une solution à trois classes, correspondant à des groupes de tailles respectives de 16, 8 et 3 pays.

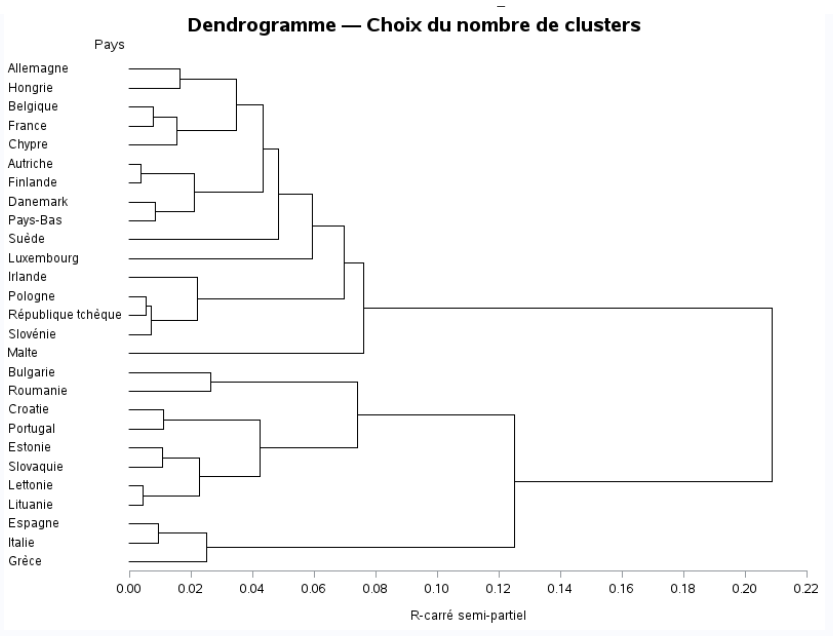

Figure 3 – *Dendrogramme*

4.3 *Description synthétique des profils de classes*

Les profils de classes sont décrits à partir des moyennes des variables calculées pour chaque groupe, sur les échelles originales des indicateurs. Cette description vise à caractériser les configurations moyennes associées à chaque classe, sans procéder à des tests de différences statistiques.

La première classe, qui regroupe 16 pays, présente en moyenne des niveaux plus élevés de satisfaction dans la vie, associés à des valeurs plus faibles des indicateurs d'inégalités et de privations matérielles. Elle se caractérise également

par des conditions de marché du travail plus favorables, avec un taux d'emploi plus élevé et des taux de chômage plus faibles, ainsi que par un effort de recherche et développement plus important.

La deuxième classe, composée de 8 pays, se distingue par des niveaux moyens plus élevés de dispersion des revenus et de pauvreté en conditions de vie, combinés à une satisfaction dans la vie plus faible. Les indicateurs du marché du travail y sont globalement moins favorables, avec des taux de chômage plus élevés et un taux d'emploi plus faible en moyenne. Les dépenses de recherche et développement y sont également plus limitées.

La troisième classe, qui ne comprend que 3 pays, doit être interprétée avec prudence en raison de sa taille réduite. Elle se caractérise par des niveaux moyens élevés de dette publique, des taux de chômage importants, en particulier chez les jeunes, et un taux d'emploi plus faible. Les moyennes observées dans cette classe sont plus sensibles à des valeurs extrêmes, ce qui justifie une lecture prudente de ce profil.

Indicateur	**Cluster 1**	**Cluster 2**	**Cluster 3**
Espérance de vie en bonne santé, femmes	63.83	59.54	67.27
Espérance de vie en bonne santé, hommes	63.13	57.59	66.17
Satisfaction dans la vie	7.56	6.81	6.93
Dispersion des revenus	4.04	5.73	5.97
Pauvreté en conditions de vie	7.64	15.79	18.63
Sorties précoces du système scolaire (%)	7.81	8.01	9.83
Taux d'emploi des 15–64 ans (%)	73.96	70.36	61.73
Dépenses de R&D (% du PIB)	2.13	1.09	1.47
Dette publique (% du PIB)	62.14	50.99	142.97
Endettement des ménages (% du PIB)	58.41	33.31	52.03
Endettement des SNF (% du PIB)	102.01	51.68	71.83
Émissions de GES par habitant (t CO_2)	8.79	6.94	6.83
Artificialisation des sols (%)	7.11	2.95	4.77
Taux de chômage 15–24 ans (%)	12.28	17.03	28.30
Taux de chômage 15–74 ans (%)	4.66	5.94	11.71
Croissance du PIB réel par tête (%)	3.53	3.33	5.10

Table 3 – *Comparaison des moyennes des indicateurs par cluster.*

4.4 *Mise en relation avec l'analyse en composantes principales*

La typologie obtenue par classification hiérarchique est cohérente avec la structure révélée par l'analyse en composantes principales. Les deux premiers axes factoriels expliquent une part substantielle de la variance totale et opposent notamment des variables liées aux inégalités et à la pauvreté à des indicateurs de bien-être subjectif et de situation sur le marché du travail.

Sur le plan factoriel formé par les deux premiers axes, les pays appartenant à une même classe tendent à se regrouper dans des zones proches, ce qui suggère que

la classification prolonge la lecture fournie par l'ACP sous la forme d'un découpage en groupes discrets. La troisième classe apparaît plus nettement isolée sur le plan factoriel, tandis que les deux autres classes correspondent à des regroupements plus progressifs le long des axes principaux.

Cette cohérence entre ACP et CAH renforce la pertinence de la typologie comme outil de synthèse de l'information multidimensionnelle.

4.5 *Transition vers l'analyse discriminante*

La classification hiérarchique ascendante fournit une typologie descriptive, mais ne permet pas d'évaluer directement la capacité des variables à discriminer les groupes obtenus. Une analyse discriminante constitue donc une étape complémentaire pertinente afin de valider la séparation entre classes, d'identifier les variables les plus discriminantes et d'évaluer la robustesse de la typologie, notamment au regard de la petite taille de la troisième classe.

5 Analyse discriminante : validation de la typologie

L'analyse discriminante canonique intervient ici *après* la classification hiérarchique (méthode de Ward), non pas pour construire les groupes, mais pour **évaluer** si les classes obtenues (clusters) sont correctement séparées au regard des variables initiales. Elle fournit des axes canoniques maximisant la séparation inter-classes, une règle de classement permettant d'estimer des taux de bonne classification, ainsi que des indications sur les variables contribuant le plus à la discrimination.

La procédure `DISCRIM` est appliquée sur 27 pays, répartis en trois classes de tailles inégales (16, 8 et 3). Sur les données de calibration (resubstitution), la matrice de classification met en évidence une restitution parfaite : l'ensemble des observations est reclassé dans son groupe d'origine, ce qui conduit à un taux d'erreur estimé nul. Par ailleurs, les distances de Mahalanobis au carré entre classes sont élevées (par exemple 42.15 entre les clusters 1 et 2, et 111.67 entre les clusters 1 et 3), et les tests associés rejettent l'hypothèse d'égalité des centres de classes, ce qui confirme une séparation statistiquement significative dans l'espace multivarié.

Avec trois groupes, l'analyse discriminante génère deux fonctions canoniques. Les corrélations canoniques associées sont élevées (0.9645 pour la première fonction et 0.9284 pour la seconde), et les tests globaux indiquent que ces dimensions discriminent significativement les classes (Pr>F = 0.0003 pour l'ensemble des fonctions, puis 0.0139 pour la seconde conditionnellement à la première). Les valeurs propres montrent que la première fonction canonique concentre l'essentiel du pouvoir discriminant (68.1% de l'information), la seconde venant compléter la séparation (31.9%). Les moyennes de classes sur ces axes confirment une structuration nette de la typologie : le cluster 1 se situe du côté positif de la première fonction canonique, le cluster 2 présente des scores négatifs sur les deux axes, tandis que le cluster 3 combine une valeur très négative sur le premier axe et positive sur le second. Cette organisation est cohérente avec la projection graphique sur le plan canonique.

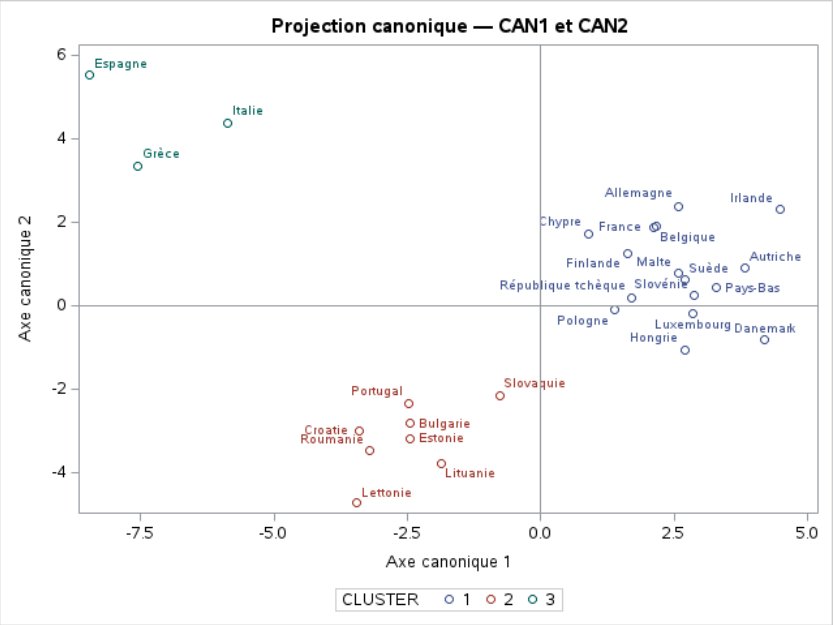

Figure 4 – *Projection canonique des pays sur CAN1 et CAN2 (analyse discriminante)*

L'identification des variables discriminantes repose sur l'analyse de la structure canonique inter-classe, c'est-à-dire les corrélations entre les variables initiales et les axes canoniques. Le premier axe est principalement associé à des variables relatives au marché du travail et aux conditions socio-économiques, telles que la pauvreté en conditions de vie, la dispersion des revenus, le chômage des jeunes et le taux d'emploi, auxquelles s'ajoutent certaines variables environnementales et d'innovation, comme les émissions de gaz à effet de serre par habitant ou les dépenses de R&D. Le second axe est dominé par les indicateurs de santé, en particulier les espérances de vie en bonne santé, et s'accompagne de variables macro-financières telles que la dette publique, la croissance du PIB réel par tête ou l'endettement des ménages, ainsi que, plus marginalement, l'artificialisation des sols.

Ces résultats doivent néanmoins être interprétés avec prudence. D'une part, la qualité de classification observée repose sur une procédure de resubstitution, connue pour surestimer la performance prédictive en l'absence de validation croisée ou d'échantillon test. D'autre part, la taille réduite de l'échantillon et le fort déséquilibre des effectifs entre classes, notamment la présence d'un groupe très restreint, peuvent affecter la stabilité des estimations. Enfin, les hypothèses sous-jacentes à l'analyse discriminante linéaire (normalité multivariée au sein des groupes, homogénéité des matrices de covariance) ne sont pas explicitement testées ici. L'analyse discriminante doit donc être comprise comme un outil de **validation interne** de la typologie, indiquant une séparation nette dans l'échantillon étudié, sans préjuger de la robustesse de cette classification hors échantillon.

6 Conclusion

Ce travail avait pour objectif d'explorer les profils de développement durable des pays de l'Union européenne en 2020 à l'aide d'une approche multivariée, fondée sur un ensemble cohérent d'indicateurs sociaux, économiques et environnementaux. La démarche adoptée s'est articulée autour de plusieurs étapes complémentaires : une analyse descriptive et des corrélations afin de caractériser la dispersion des indicateurs et leurs relations, une analyse en composantes principales visant à synthétiser l'information et à faire émerger des dimensions latentes, puis une classification hiérarchique destinée à formaliser une typologie des pays, enfin examinée à l'aide d'une analyse discriminante canonique. L'ensemble de ces méthodes a été mobilisé dans une logique de cohérence interne, sans recherche de relations causales ni formulation de jugements normatifs.

L'apport principal de cette approche réside dans sa capacité à structurer une information initialement complexe et fortement corrélée. L'analyse en composantes principales met en évidence quelques gradients majeurs de différenciation entre pays, notamment autour des conditions socio-économiques, du fonctionnement du marché du travail, du bien-être subjectif et de certains aspects macro-financiers et environnementaux. La classification hiérarchique prolonge cette lecture en regroupant les pays en un nombre limité de classes aux profils distincts, tout en conservant un lien direct avec les indicateurs initiaux. L'analyse discriminante confirme que ces groupes sont nettement séparés dans l'espace multivarié, ce qui renforce la cohérence interne de la typologie obtenue, tout en rappelant que cette validation repose sur l'échantillon étudié.

Plusieurs limites doivent néanmoins être soulignées. D'une part, l'analyse repose sur une coupe transversale unique correspondant à l'année 2020, marquée par un contexte macroéconomique particulier, ce qui limite la portée temporelle des résultats. D'autre part, le choix et le nombre restreint d'indicateurs, bien que justifiés par leur disponibilité et leur pertinence institutionnelle, ne permettent pas de couvrir l'ensemble des dimensions du développement durable. Enfin, certaines méthodes mobilisées, en particulier l'analyse discriminante, reposent sur des hypothèses statistiques qui ne sont pas testées ici et sur une validation interne susceptible de surestimer la qualité de la classification, notamment en raison de la taille réduite et du déséquilibre des groupes.

Ces résultats ouvrent néanmoins plusieurs perspectives de prolongement. Une extension naturelle consisterait à adopter une approche dynamique, en exploitant des données de panel afin d'analyser l'évolution des profils de pays dans le temps. L'enrichissement du jeu d'indicateurs ou la comparaison avec d'autres méthodes de classification pourrait également permettre de tester la robustesse des typologies obtenues. Enfin, ce type d'analyse peut constituer une base descriptive utile à des travaux ultérieurs visant à étudier plus finement les interactions entre les différentes dimensions du développement durable dans un cadre économétrique adapté.

7 Annexe

7.1 code

7.1.1 00_start.sas

```
proc import
    datafile="/home/u64356078/Cours Har/Projet/europe.xlsx"
    out=M1.europe
    dbms=xlsx
    replace;
    getnames=yes;
run;
```

7.1.2 01_clean.sas

```
options validvarname=any;

/*=========================
  0) PARAMÈTRES À ADAPTER
========================*/
%let LIB   = M1;
%let DATA  = EUROPE;
%let IDVAR = PAYS;
%let INDS  = &LIB..&DATA;

/*==========================================================
  1) CONTENU + APERÇU
==========================================================*/
title "PROC CONTENTS - &INDS";
proc contents data=&INDS varnum;
run;

title "Aperçu (10 obs) - &INDS";
proc print data=&INDS(obs=10);
run;
title;

/*==========================================================
Lister les variables CHAR candidates pour l'ID pays
==========================================================*/
title "Variables CHAR candidates pour l'identifiant pays - &INDS";
proc sql;
  create table work._id_candidates as
  select name, coalesce(label,"") as var_label length=200, length
  from dictionary.columns
```

```
  where libname = upcase("&LIB")
    and memname = upcase("&DATA")
    and type = "char"
  order by name;
quit;

proc print data=work._id_candidates noobs;
run;
title;

/*============================================================
  2) NETTOYAGE : WORK.EUROPE_CLEAN
============================================================*/
data work.europe_clean;
  set &INDS;
  if missing(&IDVAR) then delete;
run;

/* Contrôle nb obs avant/après (FIX : pas de sous-requête sans FROM) */
title "Contrôle - nb obs avant/après nettoyage";
proc sql;
  create table work._nobs as
  select "Avant" as etape length=10, count(*) as N from &INDS
  union all
  select "Apres" as etape length=10, count(*) as N from work.europe_clean;
quit;

proc print data=work._nobs noobs;
run;
title;

/*============================================================
  3) DICO VARIABLES : WORK.DICO_VARS
============================================================*/
proc sql;
  create table work.dico_vars as
  select
    name                              as var_sas   length=32,
    coalesce(label,"")                as var_label length=200,
    upcase(type)                      as var_type  length=4,
    ""                                as domaine   length=10,
    ""                                as sens      length=12
  from dictionary.columns
  where libname = "WORK"
    and memname = "EUROPE_CLEAN"
  order by var_sas;
quit;
```

```
data work.dico_vars;
  set work.dico_vars;

  length _txt $400;
  _txt = upcase(catx(" ", var_sas, var_label));

  /* ---- Domaine ---- */
  if prxmatch('/(GES|GAZ|EMISS|EMISSION|CARB|CO2|ARTIFIC|SOLS|TERRE|LAND)/', _txt) then domaine = "env";
  else if prxmatch('/(PIB|GDP|CROISS|GROW|DETTE|DEBT|ENDETT|R&D|RD|RECH|INVEST)/', _txt) then domaine = "eco";
  else if prxmatch('/(SANTE|HEALTH|ESPERANCE|VIE|HLY|SATISFACTION|REVENU|INCOME|DISPERS|POUV|PAUVRE|SCOL|EDUC|EMPLOI|UNEMP|CHOM|JEUN)/', _txt) then domaine = "social";
  else domaine = "a_revoir";

  /* ---- Sens ----
     PLUS=BON : esprance de vie en bonne sant, satisfaction, emploi, R&D, croissance PIB/tte
     PLUS=MAUVAIS : chmage, pauvret, sorties prcoces scolaires, dispersion revenus, dettes/endettements, GES/hab, artificialisation sols
  */
  if prxmatch('/(ESPERANCE|VIE|HLY|SATISFACTION)/', _txt) then sens = "PLUS=BON";
  else if prxmatch('/(TAUX.*EMPLOI|EMPLOI)/', _txt) then sens = "PLUS=BON";
  else if prxmatch('/(R&D|RD|RECH)/', _txt) then sens = "PLUS=BON";
  else if prxmatch('/(CROISS|GROW|PIB.*REEL|REAL.*GDP)/', _txt) then sens = "PLUS=BON";
  else if prxmatch('/(CHOM|UNEMP)/', _txt) then sens = "PLUS=MAUVAIS";
  else if prxmatch('/(POUV|PAUVRE)/', _txt) then sens = "PLUS=MAUVAIS";
  else if prxmatch('/(SORTIES.*PRECOC|EARLY.*SCHOOL|DECROCH)/', _txt) then sens = "PLUS=MAUVAIS";
  else if prxmatch('/(DISPERS|DISPERSION|INEGAL|INCOME.*RATIO|S80|S20)/', _txt) then sens = "PLUS=MAUVAIS";
  else if prxmatch('/(DETTE|DEBT|ENDETT)/', _txt) then sens = "PLUS=MAUVAIS";
  else if prxmatch('/(GES|GAZ|EMISS|EMISSION|CO2)/', _txt) then sens = "PLUS=MAUVAIS";
  else if prxmatch('/(ARTIFIC|SOLS|LAND)/', _txt) then sens = "PLUS=MAUVAIS";
  else sens = "a_revoir";

  drop _txt;
run;

title "Dictionnaire des variables - WORK.DICO_VARS";
proc print data=work.dico_vars noobs;
run;
title;
```

```
/*============================================================
  4) MACRO-VARIABLE &VARLIST
============================================================*/
proc sql noprint;
  select nliteral(name)
    into :VARLIST separated by ' '
  from dictionary.columns
  where libname = "WORK"
    and memname = "EUROPE_CLEAN"
    and type = "num"
    and upcase(name) ne upcase("&IDVAR")
  order by varnum;
quit;

%put NOTE: VARLIST=&VARLIST;

/*============================================================
  5) STANDARDISATION : WORK.EUROPE_STD
============================================================*/
proc stdize data=work.europe_clean out=work.europe_std method=std;
  var &VARLIST;
run;

title "Aperçu (10 obs) - WORK.EUROPE_STD";
proc print data=work.europe_std(obs=10);
run;
title;
```

7.1.3 02_descriptif_corr.sas

```
options validvarname=any;

title;
footnote;

/*============================================================
  1) STATISTIQUES DESCRIPTIVES
============================================================*/
title "Statistiques descriptives - Indicateurs UE 2020";

proc means data=work.europe_clean
           n mean std min p25 median p75 max
           maxdec=2;
  var &VARLIST;
run;
```

```
title;

/*==========================================================
  2) MATRICE DE CORRÉLATIONS
==========================================================*/
title "Matrice de corrélations (Pearson) - Indicateurs UE 2020";

proc corr data=work.europe_clean pearson nosimple;
  var &VARLIST;
run;

title;
```

7.1.4 03_acp.sas

```
options validvarname=any;

title;
footnote;

/*==========================================================
  1) ACP - PROC PRINCOMP
==========================================================*/
title "ACP - Indicateurs de développement durable (UE, 2020)";

proc princomp data=work.europe_clean
              out=work.acp_scores
              plots=none;
  var &VARLIST;
run;

title;

/*==========================================================
  2) Corrélations variables / composantes
==========================================================*/
proc corr data=work.acp_scores noprint
          outp=work.corr_acp;
  var prin1 prin2 prin3;
  with &VARLIST;
run;

data work.corr_acp;
  set work.corr_acp;
  if _TYPE_="CORR";
```

```
run;

/*==========================================================
  3) Cercle des corrélations (axes 1 et 2)
==========================================================*/
title "Cercle des corrélations - Axes 1 et 2";

proc sgplot data=work.corr_acp;
  refline 0 / axis=x;
  refline 0 / axis=y;

  scatter x=prin1 y=prin2 / datalabel=_NAME_;

  xaxis label="Axe 1";
  yaxis label="Axe 2";
run;

title;

/*==========================================================
  4) Projection des pays - plan factoriel (1,2)
==========================================================*/
title "Projection des pays - ACP (axes 1 et 2)";

proc sgplot data=work.acp_scores;
  refline 0 / axis=x;
  refline 0 / axis=y;

  scatter x=prin1 y=prin2 / datalabel=&IDVAR;

  xaxis label="Axe 1";
  yaxis label="Axe 2";
run;

title;
```

7.1.5 04_cluster.sas

```
options validvarname=any;

title;
footnote;

/*==========================================================
  1) Préparation : données standardisées
==========================================================*/
```

```
title "Données standardisées - base pour la classification";

proc print data=work.europe_std(obs=5);
run;

title;

/*============================================================
  2) Classification hiérarchique
============================================================*/
title "Classification hiérarchique - Méthode de Ward";

proc cluster data=work.europe_std
             method=ward
             outtree=work.tree
             pseudo
             ccc;
  var &VARLIST;
  id &IDVAR;
run;

title;

/*============================================================
  3) Dendrogramme
============================================================*/
title "Dendrogramme - Choix du nombre de clusters";

proc tree data=work.tree
          nclusters=3
          out=work.cluster3
          horizontal;
  id &IDVAR;
run;

title;

/*============================================================
  4) Fusion avec les données d'origine
============================================================*/

/* Trier les deux datasets par l'identifiant pays */
proc sort data=work.europe_clean;
  by &IDVAR;
run;

proc sort data=work.cluster3;
  by &IDVAR;
```

```
run;

/* Fusion propre */
data work.europe_class;
  merge work.europe_clean work.cluster3;
  by &IDVAR;
run;

/*==========================================================
  5) Description des clusters
==========================================================*/
title "Description des clusters - Moyennes des indicateurs";

proc means data=work.europe_class
           mean std
           maxdec=2;
  class cluster;
  var &VARLIST;
run;

title;
```

7.1.6 05_discriminante.sas

```
options validvarname=any;

title;
footnote;

/*==========================================================
  1) Analyse discriminante canonique
==========================================================*/
title "Analyse discriminante canonique - Validation des clusters";

proc discrim data=work.europe_class
             canonical
             distance
             list
             out=work.discrim_scores;
  class cluster;
  var &VARLIST;
run;

title;

/*==========================================================
```

```
  2) Projection canonique (CAN1, CAN2)
==========================================================*/
title "Projection canonique - CAN1 et CAN2";

proc sgplot data=work.discrim_scores;
  scatter x=can1 y=can2 / group=cluster datalabel=&IDVAR;
  refline 0 / axis=x;
  refline 0 / axis=y;

  xaxis label="Axe canonique 1";
  yaxis label="Axe canonique 2";
run;

title;
```