



Économétrie

Université de Pau et des Pays de l'Adour

Exercices sur données de panel et modèles de censure

Ce document constitue le rendu de l'examen d'économétrie de l'année universitaire 2025–2026. Il regroupe les réponses aux deux exercices demandés : la modélisation des dépenses de santé *out-of-pocket* à partir des données LSMS Guinée (exercice 1), et l'estimation de la vitesse de convergence sur données de panel (exercice 2). Les résultats présentés sont issus des traitements réalisés sous R ; le code correspondant est fourni en annexe via GitHub.

1

EXERCICE 1 : DÉPENSES DE SANTÉ OUT-OF-POCKET

1.1 Présentation des données

Les données proviennent de l'enquête *Guinea Living Standards Measurement Study* (LSMS) 2018–2019. La variable d'intérêt, `oops_sante`, mesure les dépenses de santé à la charge des ménages (*out-of-pocket*). L'échantillon brut comprend $N = 41\,434$ observations sans valeur manquante sur cette variable.

Structure de la variable dépendante. La distribution de `oops_sante` présente deux caractéristiques structurelles importantes. Premièrement, une masse de probabilité non négligeable en zéro : 29,17 % des ménages déclarent une dépense nulle, ce qui suggère un processus de génération des données en deux régimes distincts (participation vs. montant dépensé). Deuxièmement, une asymétrie positive marquée ($\text{skewness} = 2,12$) sur la partie strictement positive. Cette asymétrie est partiellement corrigée par transformation logarithmique ($\text{skewness} = -0,95$ sur $\ln(\text{oops_sante})$), ce qui motive l'estimation en log pour la partie continue.




Figure 1.1 – *Distribution de `oops_sante` (gauche) et de $\ln(\text{oops_sante})$ sur la partie strictement positive (droite).*

Variables explicatives retenues. Après examen du dictionnaire des variables, les régresseurs suivants ont été retenus : caractéristiques du chef de ménage (`hage`, `hgender`, `hmstat`, `heduc`, `halfab`), taille du ménage (`hhsz`), niveau de vie (`pcexp`), indicateur de handicap (`hhandig`), recours aux soins (`s03q05`, `s03q19`, `s03q32`), et localisation géographique (`milieu`, `region`, `prefecture`). La variable `dnal` capte l'accès à la consommation non-alimentaire. La dépense per capita (`pcexp`) présente une corrélation de 0,254 avec `oops_sante`, ce qui en fait le principal déterminant continu attendu.

Échantillon effectif. L'introduction de `s03q05` dans les modèles induit 10 409 valeurs manquantes supplémentaires (listwise deletion), ramenant l'échantillon à $N = 31\,025$ observations. La variable `s03q01` a été exclue car elle devient constante sur cet échantillon. Par ailleurs, `prefecture` et `milieu` ont été écartées des modèles de Heckman et two-part en raison d'une colinéarité parfaite avec `region`.

1.2 Estimation des modèles

Quatre spécifications sont estimées. Le tableau 1.1 en synthétise les résultats sur le coefficient de `pcexp`, retenu comme indicateur de comparaison central.

Table 1.1 – Coefficient de `pcexp` selon le modèle

Modèle	Coeff.	Stat. de test	p -valeur	Erreurs std.
OLS	$6,52 \times 10^{-3}$	$t = 7,32$	$< 0,001$	HC3
Tobit	$5,33 \times 10^{-3}$	$z = 5,83$	$< 0,001$	MLE
Heckman (équation de résultat)	$9,02 \times 10^{-3}$	$t = 10,09$	$< 0,001$	non corrigées ^a
Two-Part : probit	$-2,47 \times 10^{-9}$	$z = -0,54$	n.s.	MLE
Two-Part : OLS log	$2,59 \times 10^{-8}$	$t = 8,67$	$< 0,001$	HC3

^a Les erreurs standard de l'équation de résultat de Heckman sont issues de l'estimateur two-step sans correction de la variance (voir section 1.3).

Table 1.2 – Critères d'ajustement comparatifs

Modèle	N	Log-lik.	AIC	BIC	$\hat{\sigma}$
OLS	31 025	-430 835	861 790	862 291	260 073
Tobit	31 025	-333 518	667 170	667 729	312 673
Heckman (step 2)	23 341	(2-step, non comparable)			
Two-Part probit	31 025	-11 863	23 791	24 058	
Two-Part OLS log	23 341	-30 653	61 371	61 637	0,90

Les AIC/BIC OLS et Tobit ne sont pas comparables entre eux (variables dépendantes de nature différente : niveau vs censuré). Le Heckman two-step ne produit pas de vraisemblance jointe dans cette implémentation.

OLS. L'OLS sur niveau est estimé avec erreurs standard robustes à l'hétéroscédasticité (HC3), justifiées par le test de Breusch–Pagan ($BP = 2017,6$, $p < 0,001$). Le test RESET ($F = 496,15$, $p < 0,001$) rejette l'adéquation de la forme fonctionnelle linéaire, ce qui ne surprend pas compte tenu de la distribution de la variable dépendante.

Tobit. Le modèle Tobit de type I postule un processus latent continu censuré en zéro :

$$y_i = \max(0, \mathbf{x}_i' \boldsymbol{\beta} + \varepsilon_i), \quad \varepsilon_i \sim \mathcal{N}(0, \sigma^2). \quad (1.1)$$

Ce modèle impose que les mêmes variables et les mêmes paramètres gouvernent simultanément la participation et le montant. Cette contrainte est discutable ici.

Modèle de sélection de Heckman. Le modèle à deux équations de Heckman découple l'équation de sélection (participation aux soins, estimée par probit) de l'équation de résultat (montant conditionnel à $y_i > 0$). La correction du biais de sélection est assurée via le ratio de Mills inverse $\hat{\lambda}_i$. Le coefficient estimé de $\hat{\lambda}_i$ est $-346\,152$ ($t = -55,64$, $p < 0,001$), ce qui confirme l'existence d'un biais de sélection statistiquement significatif.

Modèle two-part. Le modèle two-part traite les deux marges indépendamment : une équation probit pour $\Pr(y_i > 0)$, et une régression OLS sur $\ln(y_i)$ pour les observations strictement positives. La présence d'hétéroscédasticité dans la partie 2 (BP , $p < 0,001$) implique que le retour à l'échelle initiale ne peut se faire par simple exponentiation. L'estimateur de smearing de Duan a été retenu pour corriger ce biais de retransformation.

Un résultat appelle attention : le coefficient de `pcexp` dans le probit est numériquement négligeable ($-2,47 \times 10^{-9}$, non significatif), alors que le même coefficient est fortement significatif dans la partie OLS log. Cette anomalie suggère soit une instabilité numérique du probit liée à l'échelle de `pcexp`, soit un effet du niveau de vie concentré sur le montant conditionnel plutôt que sur la décision de participation.

1.3 Cohérence et efficacité

Les propriétés asymptotiques des quatre estimateurs dépendent de la validité de leurs hypothèses structurelles respectives.

OLS. L'OLS est consistant si $\mathbb{E}[\varepsilon_i | \mathbf{x}_i] = 0$, ce qui requiert l'absence d'endogénéité. Cependant, il ignore la censure en zéro : en présence de cette masse de probabilité, l'OLS produit un estimateur biaisé vers le bas même asymptotiquement. Les erreurs standard HC3 corrigent l'inefficacité liée à l'hétéroscédasticité mais ne restaurent pas la consistance. L'OLS est donc *inconsistant* et *inefficace* sur données censurées.

Tobit. L'estimateur Tobit ML est consistant et asymptotiquement efficace (borne de Cramér–Rao) sous l'hypothèse de normalité et d'homoscédasticité de ε_i . Toutefois, une déviation à la normalité ou à l'homoscédasticité suffit à le rendre inconsistant.

Or, les tests réalisés (Breusch–Pagan, skewness résiduelle) indiquent une violation de ces hypothèses, ce qui fragilise ses propriétés.

Heckman two-step. L'estimateur two-step est consistant sous l'hypothèse de normalité bivariée du terme d'erreur des deux équations, et à condition que l'équation de sélection soit correctement spécifiée. Néanmoins, les erreurs standard issues de la procédure two-step ne tiennent pas compte de la variabilité introduite par l'estimation de $\hat{\lambda}_i$ à la première étape. Elles sont donc invalides pour l'inférence et sous-estiment typiquement la variance réelle. Un estimateur ML joint ou une correction sandwich serait nécessaire pour une inférence valide.

Two-part. Contrairement au Tobit et à Heckman, le modèle two-part ne requiert pas de normalité jointe ni de corrélation entre les deux processus. Il est consistant sous des hypothèses nettement plus faibles, à condition que chaque équation soit correctement spécifiée. L'hétéroscédasticité dans la partie OLS log est prise en charge par les erreurs standard HC3, et le smearing de Duan gère le biais de retransformation. Ce modèle offre ainsi le meilleur compromis robustesse/flexibilité dans ce contexte, au prix d'une moindre efficacité par rapport à un Tobit correctement spécifié.

2

EXERCICE 2 : VITESSE DE CONVERGENCE

2.1 Données

Les données proviennent de la base *World Development Indicators* (WDI) de la Banque mondiale. La variable dépendante est le taux de croissance annuel du PIB réel par habitant (`growth_gdp`). le PIB par habitant retardé d'une période en logarithme (`ln_gdp_pc_lag1`) capte la condition initiale nécessaire à l'estimation de la convergence conditionnelle; le taux d'investissement (`ln_inv`) et le taux de croissance de la population augmenté des taux de dépréciation et de progrès technique (`ln_ngd`) constituent les déterminants de l'état stationnaire dans le modèle de Solow; la variable d'ouverture commerciale (`openness`) est introduite comme contrôle supplémentaire. Le capital humain (`ln_school`) est proxyé par le taux de scolarisation secondaire, mais présente environ 15 % de valeurs manquantes. Deux spécifications sont retenues : une spécification *base* sans `ln_school` et une spécification *étendue* incluant cette variable.

Le panel est cylindré et couvre $N = 55$ pays sur $T = 33$ années (1990–2022), soit $NT = 1815$ observations dans la spécification complète. La structure équilibrée facilite l'identification des effets fixes et la mise en œuvre des estimateurs GMM.

2.2 Estimation des modèles

L'équation de base estimée est :

$$\Delta y_{it} = \alpha + \beta \ln y_{i,t-1} + \gamma' X_{it} + \eta_i + \varepsilon_{it} \quad (2.1)$$

où Δy_{it} désigne le taux de croissance du PIB par habitant, $\ln y_{i,t-1}$ la condition initiale, X_{it} le vecteur de contrôles, η_i l'effet fixe individuel inobservé et ε_{it} le terme d'erreur idiosyncratique. La vitesse de convergence est déduite du coefficient β : $\lambda = -\beta$ (en valeur absolue, exprimée en %).

Le tableau 2.1 présente les estimations de β sur `ln_gdp_pc_lag1` pour les six estimateurs retenus dans la spécification base.

Table 2.1 – *Estimations de la vitesse de convergence : spécification base*

Estimateur	$\hat{\beta}$	Écart-type	Vitesse $\hat{\lambda}$ (%)	N
POLS	-0,00382	0,00176	0,38	1 753
RE	-0,00516	0,03258	0,52	1 753
FE (Within)	-0,05308	0,01831	5,31	1 753
FD	-0,70735	0,09426	70,74	1 698
GMM-diff	+0,13223	0,10490		1 645
SYS-GMM	-0,10102	0,10552	10,10	3 345

Note : Le signe positif de $\hat{\beta}$ en GMM-diff base est statistiquement non significatif ($z = 1,26$). La vitesse n'est pas reportée pour cet estimateur. SYS-GMM est invalidé par les tests de spécification.

Validité des estimateurs GMM. La validité des conditions de moment des estimateurs GMM est vérifiée par deux tests : le test d'Arellano-Bond sur l'auto-corrélation des résidus en différences (AR(1) et AR(2)), et le test de Sargan de suridentification. L'absence d'autocorrélation d'ordre 2 est la condition nécessaire à la validité des instruments en niveaux retardés.

Table 2.2 – *Tests de spécification GMM*

Estimateur	Spécification	AR(1) p	AR(2) p	Sargan p	Validité
GMM-diff	Base	0,074	0,185	0,910	✓
GMM-diff	Étendue	0,018	0,252	0,146	✓
SYS-GMM	Base		0,011		×
SYS-GMM	Étendue			0,026	×

Note : AR(2) $p < 0,05$ en SYS-GMM base invalide les conditions de moment ; Sargan $p < 0,05$ en SYS-GMM étendu rejette la validité des instruments en niveaux. SYS-GMM n'est pas retenu. GMM-diff en spécification étendue constitue la seule spécification GMM pleinement valide.

2.3 Cohérence et efficience

On discute pour chaque estimateur les conditions sous lesquelles il est cohérent et efficient, en référence au modèle (2.1).

POLS. L'estimateur des MCO empilés est incohérent pour deux raisons cumulées. D'une part, la variable $\ln y_{i,t-1}$ est endogène par construction dans un panel dynamique : elle est corrélée à η_i via les réalisations passées, ce qui induit un biais vers zéro. D'autre part, POLS ignore l'hétérogénéité individuelle η_i , vraisemblablement corrélée aux régresseurs. Ces deux biais agissent dans le même sens et atténuent fortement $\hat{\beta}$. La vitesse estimée de 0,38 % est très inférieure à la valeur de référence de 2 % généralement obtenue dans la littérature, ce qui confirme la sous-estimation. POLS ne peut pas être retenu comme estimateur crédible.

RE. L'estimateur des effets aléatoires est cohérent uniquement si η_i est orthogonal à l'ensemble des régresseurs. Cette hypothèse est économiquement peu plausible :

les dotations en capital humain, la qualité des institutions et d'autres déterminants non observés sont structurellement corrélés aux niveaux d'investissement et au PIB initial. Le test de Hausman permet de tester formellement cette hypothèse ; si RE est rejeté en faveur de FE, RE est incohérent. Sous son hypothèse propre, RE est efficient car il exploite l'information inter-individuelle et intra-individuelle. En pratique, RE est dominé par FE sur des données macroéconomiques où la corrélation entre η_i et X_{it} est attendue.

FE (Within). L'estimateur Within élimine η_i par transformation en écarts à la moyenne individuelle, ce qui le rend cohérent sous exogénéité stricte des régresseurs conditionnellement aux effets fixes. Cependant, dans un modèle dynamique, $\ln y_{i,t-1}$ est mécaniquement corrélé au terme d'erreur transformé, ce qui induit le biais de Nickell, d'ordre $O(1/T)$. Avec $T = 33$, ce biais est faible mais non nul. FE reste l'estimateur le plus crédible parmi les trois premières spécifications, avec une vitesse estimée de 5,3 % plus proche des valeurs de la littérature.

FD. L'estimateur en premières différences élimine également η_i et est exonéré du biais de Nickell. Il est cohérent si les erreurs différenciées $\Delta \varepsilon_{it}$ ne sont pas autocorrélées. En pratique, $\hat{\beta} = -0,707$ implique une vitesse de convergence de 70,7 %, ce qui est économiquement aberrant. Deux explications sont plausibles : une forte autocorrélation sérielle des erreurs en différences, ou un problème numérique lié à la transformation FD sur ce panel. Ce résultat doit être signalé comme suspect ; FD ne peut pas être retenu sans diagnostic complémentaire.

GMM-diff. L'estimateur GMM en premières différences utilise comme instruments les valeurs retardées en niveaux de $\ln y_{i,t-1}$, corrigeant simultanément l'endogénéité de la variable dépendante retardée et le biais de Nickell. Sa validité repose sur l'absence d'autocorrélation d'ordre 2 des résidus en différences et sur la validité des instruments (test de Sargan). Ces deux conditions sont satisfaites dans les spécifications base et étendue (tableau 2.2). En spécification base, le coefficient est positif ($\hat{\beta} = +0,132$), ce qui suggérerait une divergence ; toutefois, il est statistiquement non significatif ($z = 1,26$), compatible avec une hypothèse nulle de convergence nulle. En spécification étendue, les conditions de moment sont également validées et GMM-diff constitue l'estimateur le plus crédible sur ces données.

SYS-GMM. L'estimateur SYS-GMM combine l'équation en différences et l'équation en niveaux, ce qui le rend en principe plus efficient que GMM-diff lorsque les instruments en niveaux sont faibles. Il requiert cependant une condition de moment supplémentaire sur l'équation en niveaux (stationnarité initiale). Sur ces données, SYS-GMM est invalide dans les deux spécifications : le test AR(2) est significatif en base ($p = 0,011$), invalidant les conditions de moment ; le test de Sargan est rejeté en étendue ($p = 0,026$), indiquant que les instruments en niveaux ne sont pas valides. SYS-GMM ne peut pas être retenu dans cette application.

Bilan. POLS et RE sont incohérents en raison de l'hétérogénéité corrélée et de l'endogénéité dynamique. FE est cohérent sous exogénéité stricte avec un biais de Nickell résiduel faible. FD produit un résultat aberrant qui nécessite un diagnostic d'autocorrélation. GMM-diff en spécification étendue est l'estimateur dont les hypothèses d'identification sont les mieux vérifiées sur ces données ; il constitue la référence principale pour l'interprétation de la vitesse de convergence. SYS-GMM est rejeté par les tests de spécification.



ANNEXE

L'ensemble des fichiers utilisés pour produire ce rapport (données, scripts R, Output) sont disponible à l'adresse suivante :

https://github.com/AntoineJeanEcon/CV/tree/main/Travaux/2026_M1_Econometrie