



Économétrie

Université de Pau et des Pays de l'Adour

Exercices sur données de panel et modèles de censure

Ce document constitue le rendu de l'examen d'économétrie de l'année universitaire 2025–2026. Il regroupe les réponses aux deux exercices demandés : la modélisation des dépenses de santé *out-of-pocket* à partir des données LSMS Guinée (exercice 1), et l'estimation de la vitesse de convergence sur données de panel (exercice 2). Les résultats présentés sont issus des traitements réalisés sous R ; le code correspondant est fourni en annexe via GitHub.

1

EXERCICE 1 : DÉPENSES DE SANTÉ OUT-OF-POCKET

1.1 Présentation des données

Les données utilisées sont issues de l'enquête *Guinea Living Standards Measurement Study* (LSMS) conduite en 2018–2019. La variable d'intérêt est `oops_sante`, qui capte les dépenses de santé directement supportées par les ménages. L'échantillon de départ, une fois les observations sans valeur manquante sur `oops_sante` retenues, comprend $N = 41\,434$ individus.

Structure de la variable dépendante. La distribution de `oops_sante` pose d'emblée deux problèmes pour l'estimation. D'une part, une fraction non négligeable des ménages — 29,17 % — déclare une dépense nulle. Cette concentration en zéro renvoie à deux régimes distincts : la décision de recourir ou non aux soins, et le montant effectivement dépensé une fois ce recours décidé. D'autre part, la partie strictement positive est fortement asymétrique ($\text{skewness} = 2,12$). La transformation logarithmique réduit cette asymétrie ($\text{skewness} = -0,95$ sur $\ln(\text{oops_sante})$), ce qui motive l'estimation en log pour la composante continue.




Figure 1.1 — *Distribution de `oops_sante` (gauche) et de $\ln(\text{oops_sante})$ sur la partie strictement positive (droite).*

Variables explicatives retenues. Après lecture du dictionnaire des variables, les régresseurs retenus couvrent les caractéristiques du chef de ménage (**hage**, **hgender**, **hmstat**, **heduc**, **halfab**), la taille du ménage (**hsize**), le niveau de consommation (**pcexp**), un indicateur de handicap (**hhandig**), des variables de recours aux soins (**s03q05**, **s03q19**, **s03q32**), et la localisation géographique (**milieu**, **region**, **prefecture**). La variable **dna1** capte l'accès à la consommation non-alimentaire. La dépense per capita (**pcexp**) présente une corrélation de 0,254 avec **oops_sante** et constitue le déterminant continu le plus directement attendu.

Échantillon effectif. L'inclusion de **s03q05** entraîne 10 409 suppressions supplémentaires par listwise deletion, ramenant l'échantillon à $N = 31\,025$ observations. La variable **s03q01** a été exclue : elle est constante sur cet échantillon réduit et n'apporte donc aucune information. **prefecture** et **milieu** ont par ailleurs été écartées des modèles de Heckman et two-part, en raison d'une colinéarité parfaite avec **region** sur ce sous-échantillon.

1.2 Estimation des modèles

Quatre spécifications sont estimées. Le tableau 1.1 synthétise les résultats sur le coefficient de **pcexp**, retenu comme point de comparaison entre estimateurs.

Table 1.1 – Coefficient de **pcexp** selon le modèle

Modèle	Coeff.	Stat. de test	<i>p</i> -valeur	Erreurs std.
OLS	$6,52 \times 10^{-3}$	$t = 7,32$	$< 0,001$	HC3
Tobit	$5,33 \times 10^{-3}$	$z = 5,83$	$< 0,001$	MLE
Heckman (équation de résultat)	$9,02 \times 10^{-3}$	$t = 10,09$	$< 0,001$	non corrigées ^a
Two-Part : probit	$-2,47 \times 10^{-9}$	$z = -0,54$	n.s.	MLE
Two-Part : OLS log	$2,59 \times 10^{-8}$	$t = 8,67$	$< 0,001$	HC3

^a Les erreurs standard de l'équation de résultat de Heckman sont issues de l'estimateur two-step sans correction de la variance (voir section 1.3).

Table 1.2 – Critères d'ajustement comparatifs

Modèle	<i>N</i>	Log-lik.	AIC	BIC	$\hat{\sigma}$
OLS	31 025	-430 835	861 790	862 291	260 073
Tobit	31 025	-333 518	667 170	667 729	312 673
Heckman (step 2)	23 341	(2-step, non comparable)			
Two-Part probit	31 025	-11 863	23 791	24 058	
Two-Part OLS log	23 341	-30 653	61 371	61 637	0,90

Les AIC/BIC des modèles OLS et Tobit ne sont pas comparables entre eux, les variables dépendantes étant de nature différente (niveau brut vs variable censurée). Le Heckman two-step ne produit pas de vraisemblance jointe dans cette implémentation.

OLS. L'OLS est estimé sur le niveau brut de `oops_sante` avec des erreurs standard robustes HC3. Le recours à ces erreurs est justifié par le test de Breusch–Pagan ($BP = 2017,6$, $p < 0,001$), qui rejette l'homoscédasticité. Le test RESET ($F = 496,15$, $p < 0,001$) rejette également l'adéquation de la forme fonctionnelle linéaire — résultat attendu au vu de la distribution de la variable dépendante.

Tobit. Le modèle Tobit de type I repose sur l'hypothèse d'un processus latent continu censuré en zéro :

$$y_i = \max(0, \mathbf{x}_i' \boldsymbol{\beta} + \varepsilon_i), \quad \varepsilon_i \sim \mathcal{N}(0, \sigma^2). \quad (1.1)$$

Ce faisant, il contraint les mêmes paramètres à gouverner à la fois la participation aux soins et le montant dépensé. Cette restriction est discutable : rien n'impose que les déterminants de la décision de recourir soient identiques à ceux du montant engagé.

Modèle de sélection de Heckman. Le modèle de Heckman lève cette contrainte en séparant explicitement une équation de sélection (participation aux soins, estimée par probit) et une équation de résultat (montant conditionnel à $y_i > 0$). Le biais de sélection est corrigé par l'inclusion du ratio de Mills inverse $\hat{\lambda}_i$. Le coefficient estimé de $\hat{\lambda}_i$ vaut $-346\,152$ ($t = -55,64$, $p < 0,001$) : le biais de sélection est donc statistiquement présent et quantitativement très important.

Modèle two-part. Le modèle two-part traite les deux marges de façon totalement indépendante : un probit pour $\Pr(y_i > 0)$, et une régression OLS sur $\ln(y_i)$ pour les observations avec dépense positive. L'hétéroscédasticité détectée dans la seconde partie (BP , $p < 0,001$) interdit le retour à l'échelle par simple exponentiation ; l'estimateur de smearing de Duan est utilisé pour corriger ce biais de retransformation.

Un résultat mérite d'être signalé : le coefficient de `pcexp` dans le probit est numériquement négligeable ($-2,47 \times 10^{-9}$, non significatif), alors qu'il est fortement significatif dans l'OLS log. Deux interprétations sont envisageables — instabilité numérique du probit liée à l'échelle de `pcexp`, ou effet du niveau de vie concentré sur le montant conditionnel plutôt que sur la décision d'accès aux soins. Les deux ne sont pas exclusives.

1.3 Cohérence et efficience

OLS. L'OLS est consistant si $\mathbb{E}[\varepsilon_i | \mathbf{x}_i] = 0$. Mais en présence d'une masse de probabilité en zéro non nulle, l'OLS ignore la censure et produit un estimateur biaisé vers le bas, y compris asymptotiquement. Les erreurs HC3 corrigent les conséquences de l'hétéroscédasticité sur l'inférence, mais ne restaurent pas la consistance. En données censurées, l'OLS est donc à la fois inconsistant et inefficace.

Tobit. L'estimateur Tobit ML est consistant et asymptotiquement efficace au sens de Cramér–Rao, sous normalité et homoscedasticité de ε_i . Ces deux conditions sont néanmoins rejetées par les tests (Breusch–Pagan, examen de l'asymétrie résiduelle). Une déviation à l'une ou l'autre suffit à rendre l'estimateur inconsistant — ce qui fragilise sérieusement ses propriétés sur ces données.

Heckman two-step. L'estimateur two-step est consistant sous normalité bivariée des termes d'erreur et sous bonne spécification de l'équation de sélection. Mais ses erreurs standard ne tiennent pas compte de l'incertitude introduite par l'estimation de $\hat{\lambda}_i$ à la première étape : elles sous-estiment la variance réelle et sont invalides pour l'inférence. Un estimateur ML joint, ou a minima une correction sandwich, serait nécessaire pour des tests valides.

Two-part. Le two-part n'exige ni normalité jointe, ni corrélation entre les deux processus. Il est consistant sous des conditions nettement plus faibles que le Tobit ou le Heckman, à condition que chaque équation soit bien spécifiée. L'hétéroscédasticité de la partie OLS log est traitée par les erreurs HC3, et le smearing de Duan gère le biais de retransformation. C'est dans ce contexte le modèle le plus robuste, au prix d'une efficacité moindre par rapport à un Tobit qui serait correctement spécifié — ce qui n'est pas le cas ici.

2

EXERCICE 2 : VITESSE DE CONVERGENCE

2.1 Données

Les données sont tirées de la base *World Development Indicators* (WDI) de la Banque mondiale. La variable dépendante est le taux de croissance annuel du PIB réel par habitant (`growth_gdp`). Le PIB par habitant retardé d'une période en logarithme (`ln_gdp_pc_lag1`) capte la condition initiale requise pour estimer la convergence conditionnelle. Le taux d'investissement (`ln_inv`) et le taux de croissance de la population augmenté des taux de dépréciation et de progrès technique (`ln_ngd`) sont les déterminants de l'état stationnaire dans le cadre de Solow. Une variable d'ouverture commerciale (`openness`) est ajoutée comme contrôle. Le capital humain (`ln_school`), proxyé par le taux de scolarisation secondaire, présente environ 15 % de valeurs manquantes, ce qui conduit à retenir deux spécifications : une spécification *base* sans `ln_school` et une spécification *étendue* qui l'inclut.

Le panel est cylindré, couvre $N = 55$ pays sur $T = 33$ années (1990–2022), soit $NT = 1815$ observations dans la spécification complète. La structure équilibrée facilite l'élimination des effets fixes et la mise en œuvre des estimateurs GMM.

2.2 Estimation des modèles

L'équation estimée est :

$$\Delta y_{it} = \alpha + \beta \ln y_{i,t-1} + \gamma' X_{it} + \eta_i + \varepsilon_{it} \quad (2.1)$$

où Δy_{it} est le taux de croissance du PIB par habitant, $\ln y_{i,t-1}$ la condition initiale, X_{it} le vecteur de contrôles, η_i l'effet fixe individuel et ε_{it} le terme idiosyncratique. La vitesse de convergence est déduite de β : $\lambda = -\beta$, exprimée en valeur absolue et en pourcentage.

Le tableau 2.1 reporte les estimations de β pour les six estimateurs dans la spécification base.

Table 2.1 – *Estimations de la vitesse de convergence : spécification base*

Estimateur	$\hat{\beta}$	Écart-type	Vitesse $\hat{\lambda}$ (%)	N
POLS	−0,00382	0,00176	0,38	1 753
RE	−0,00516	0,03258	0,52	1 753
FE (Within)	−0,05308	0,01831	5,31	1 753
FD	−0,70735	0,09426	70,74	1 698
GMM-diff	+0,13223	0,10490		1 645
SYS-GMM	−0,10102	0,10552	10,10	3 345

Note : Le signe positif de $\hat{\beta}$ en GMM-diff base est statistiquement non significatif ($z = 1,26$). La vitesse n'est pas reportée pour cet estimateur. SYS-GMM est invalidé par les tests de spécification.

Validité des estimateurs GMM. La validité des conditions de moment est vérifiée par le test d'Arellano-Bond sur l'autocorrélation des résidus en différences (AR(1) et AR(2)) et par le test de Sargan de suridentification. L'absence d'autocorrélation d'ordre 2 est la condition nécessaire à la validité des instruments en niveaux retardés.

Table 2.2 – *Tests de spécification GMM*

Estimateur	Spécification	AR(1) p	AR(2) p	Sargan p	Validité
GMM-diff	Base	0,074	0,185	0,910	✓
GMM-diff	Étendue	0,018	0,252	0,146	✓
SYS-GMM	Base		0,011		×
SYS-GMM	Étendue			0,026	×

Note : AR(2) $p < 0,05$ en SYS-GMM base invalide les conditions de moment ; Sargan $p < 0,05$ en SYS-GMM étendu rejette la validité des instruments en niveaux. SYS-GMM n'est donc pas retenu. GMM-diff en spécification étendue est la seule configuration GMM pleinement valide sur ces données.

2.3 Cohérence et efficience

POLS. En panel dynamique, POLS cumule deux sources d'incohérence. La variable $\ln y_{i,t-1}$ est endogène par construction — elle est corrélée à η_i via les réalisations passées, ce qui tire $\hat{\beta}$ vers zéro. Et POLS ignore l'hétérogénéité individuelle η_i , qui est vraisemblablement corrélée aux régresseurs. Ces deux biais s'additionnent et expliquent la vitesse estimée de 0,38 %, très en deçà des 2 % usuellement obtenus dans la littérature de convergence. POLS ne constitue pas un estimateur crédible ici.

RE. L'estimateur à effets aléatoires n'est consistant que si η_i est orthogonal à X_{it} — hypothèse économiquement difficile à défendre sur données macroéconomiques : les dotations en capital humain, la qualité institutionnelle, et d'autres facteurs non observés sont structurellement liés aux niveaux d'investissement et au PIB initial. Le test de Hausman permet de tester formellement cette orthogonalité ; si RE est

rejeté en faveur de FE, RE est inconsistant. Sous son hypothèse propre, RE serait efficient. En pratique, il est dominé.

FE (Within). L'estimateur Within élimine η_i par transformation en écarts à la moyenne individuelle. Il est consistant sous exogénéité stricte des régresseurs conditionnellement aux effets individuels. Mais dans un modèle dynamique, $\ln y_{i,t-1}$ se retrouve mécaniquement corrélé au terme d'erreur transformé, générant le biais de Nickell d'ordre $O(1/T)$. Avec $T = 33$, ce biais reste limité. FE demeure l'estimateur le plus crédible parmi les trois premiers, avec une vitesse de 5,3 % cohérente avec les ordres de grandeur de la littérature.

FD. L'estimateur en premières différences élimine également η_i et n'est pas affecté par le biais de Nickell. Il est consistant si les erreurs différenciées $\Delta \varepsilon_{it}$ ne sont pas autocorrélées. Or $\hat{\beta} = -0,707$, soit une vitesse de convergence de 70,7 %, est économiquement aberrant. Deux hypothèses : autocorrélation sérielle des erreurs différenciées, ou instabilité numérique de la transformation FD sur ce panel particulier. Ce résultat ne peut pas être retenu sans diagnostic complémentaire.

GMM-diff. GMM en premières différences instrumente $\ln y_{i,t-1}$ par ses retards en niveaux, corrigeant simultanément l'endogénéité de la variable dépendante retardée et le biais de Nickell. Sa validité dépend de l'absence d'autocorrélation d'ordre 2 et de la validité des instruments (Sargan). Ces deux conditions sont satisfaites dans les deux spécifications (tableau 2.2). En base, le coefficient positif ($\hat{\beta} = +0,132$) serait interprétable comme une divergence — mais il est non significatif ($z = 1,26$) et compatible avec une hypothèse nulle de convergence nulle. En spécification étendue, les conditions de moment sont validées et GMM-diff est l'estimateur dont les hypothèses d'identification sont les mieux vérifiées.

SYS-GMM. SYS-GMM combine l'équation en différences et l'équation en niveaux, ce qui devrait le rendre plus efficient que GMM-diff lorsque les instruments en niveaux sont faibles. Mais cette efficacité potentielle a un coût : une condition de moment supplémentaire sur l'équation en niveaux (stationnarité initiale). Sur ces données, cette condition n'est pas vérifiée. Le test AR(2) est significatif en base ($p = 0,011$), ce qui invalide les instruments GMM-diff sous-jacents ; le test de Sargan est rejeté en étendue ($p = 0,026$), ce qui indique que les instruments en niveaux ajoutés ne sont pas valides. SYS-GMM ne peut pas être retenu dans cette application.

Bilan. POLS et RE sont inconsistants pour des raisons qui tiennent à la structure même du problème — hétérogénéité corrélée et endogénéité dynamique. FE est consistant sous exogénéité stricte, avec un biais de Nickell résiduel faible à $T = 33$. FD produit un résultat aberrant qui appelle un diagnostic d'autocorrélation avant toute interprétation. GMM-diff en spécification étendue est l'estimateur dont les conditions d'identification sont les mieux vérifiées ; c'est sur lui que doit reposer l'interprétation de la vitesse de convergence. SYS-GMM est rejeté par les tests.



ANNEXE

L'ensemble des fichiers utilisés pour produire ce rapport (données, scripts R, outputs) sont disponibles à l'adresse suivante :

https://github.com/AntoineJeanEcon/CV/tree/main/Travaux/2026_M1_Econometrie